



Ford Innovation Challenge III – AI Edition

Predicción temprana de la degradación del filtro de partículas
a partir de la telemetría de vehículos conectados

Área: Data-Driven Powertrain Intelligence

Equipo SOG

Santino Cardelli · Gonzalo Malaspina · Octavio Romagnoli

Octubre 2026

Resumen

En este trabajo se desarrolló y se validó un método para anticipar la saturación del filtro de partículas diésel (DPF) a partir de la telemetría que los vehículos conectados de Ford ya transmiten: resúmenes de viaje y mensajes del sistema de postratamiento. El problema se formuló como un panel de cortes cada $\Delta = 500$ km, donde en cada corte un modelo observa los últimos $W = 1.000$ km y asigna un puntaje de riesgo de que el evento ocurra entre $G = 500$ y $G + H = 3.500$ km más adelante, sin acceso a los 500 km inmediatamente previos. Antes de modelar se identificaron y corrigieron sesgos de muestreo y de formato que inflaban cualquier métrica: dos cohortes muestreadas en períodos de producción distintos, una fecha de evento posterior a la intervención en taller y un contador de regeneraciones que deja de reportar. Como el PR-AUC por fila de este panel premia reconocer qué vehículo va a fallar aunque no se anticipe cuándo, los modelos se evaluaron con una métrica que exige anticipar: la detección por vehículo a un presupuesto fijo de falsas alarmas, contrastada con un nulo de permutación que conserva el largo de cada historial. Sobre más de 40 configuraciones (modelos lineales, *gradient boosting*, supervivencia en tiempo discreto y redes recurrentes), el modelo finalista es una red GRU con atención de ~ 3.900 parámetros sobre una secuencia de 20 tramos de $50 \text{ km} \times 15$ canales, más país, motor y serie, combinada en un ensamble por rango de tres semillas. En un conjunto de prueba de 111 vehículos que nunca se usó para entrenar ni para ajustar (103 con datos, 32 con evento), detecta $\sim 30\%$ de los eventos con 5% de vehículos sanos con falsa alarma (el nulo da 7%), $\sim 40\text{--}50\%$ con 10% y $\sim 50\text{--}60\%$ con 20% , con una mediana de ~ 4.600 km (unos tres meses) entre la primera alerta y el evento. Con el umbral fijado en desarrollo, las falsas alarmas realizadas en prueba fueron 5,8, 8,9 y 18,2%. Cada alerta entra en un circuito de posventa: una política determinista que define Ford decide la acción (un consejo de manejo al conductor o un contacto del concesionario), y agentes de lenguaje redactan los avisos bajo un verificador programado que impide que inventen números o diagnósticos. El costo de operación estimado es de USD 0,07–0,10 por vehículo y por año, sin sensores adicionales.

Índice

Resumen	1
1. Descripción general del desafío	3
2. Contexto del proceso	4
3. Definición del desafío	4
4. Datos técnicos relevantes	6
5. Expectativas de solución	9
6. Producto: de la alerta a la acción	17
7. Información complementaria	18
8. Conclusión	19
Referencias	19
A. Auditorías de fuga de información	20
B. Resultados de todos los modelos	21
C. Diccionario de variables	22

1. Descripción general del desafío

El desafío pide una metodología basada en inteligencia artificial para predecir eventos de degradación de la eficiencia de combustión y del ingreso de oxígeno al motor a partir de datos de vehículos conectados [1]. En un motor diésel, el componente que se degrada por el uso y que afecta a la vez la combustión y el flujo de gases es el filtro de partículas (DPF): una restricción del escape aumenta la contrapresión, empeora el llenado de los cilindros y obliga a la unidad de control a modificar la estrategia de inyección [2].

1.1. Física del filtro de partículas

El DPF retiene el hollín del escape en las paredes de un monolito cerámico. La masa de hollín acumulada m_s evoluciona según un balance entre lo que ingresa y lo que se oxida,

$$\frac{dm_s}{dt} = \dot{m}_{\text{in}} - k(T) m_s, \quad k(T) = A \exp\left(-\frac{E_a}{RT}\right), \quad (1)$$

donde $\dot{m}_{\text{in}}$ es el caudal de hollín emitido por el motor, T la temperatura del filtro y $k(T)$ una constante de oxidación de tipo Arrhenius [2]. Por la dependencia exponencial con T , la oxidación solo es apreciable por encima de umbrales de temperatura: la regeneración pasiva con NO_2 opera aproximadamente entre 250 y 450 °C, y la activa con O_2 requiere más de ~ 550 °C, que la unidad de control fuerza con postinyección cuando la carga estimada supera un umbral [2]. Una regeneración activa necesita, por lo tanto, varios minutos de motor caliente con carga sostenida. En un uso con viajes cortos, ralenti prolongado o motor por debajo de su temperatura de régimen, la regeneración comienza y se interrumpe; el segundo término de la ecuación (1) queda chico frente al primero, la carga crece y el vehículo termina en un modo de protección y en el taller.

De la ecuación (1) se desprenden dos consecuencias que orientaron el trabajo. Primero, el estado del filtro es *reversible*: la carga de hollín se reduce con cada regeneración completa, a diferencia de la ceniza, que se acumula de forma irreversible pero en escalas de más de 10^5 km [2]. Segundo, el riesgo depende de la *historia de uso reciente* (temperaturas alcanzadas, duración de los viajes, tiempo detenido) más que del kilometraje acumulado.

1.2. Lo que se encontró en los datos

El evento es del filtro, con otra denominación. La tabla de viajes no trae las columnas del DPF que documenta el anexo de datos, pero sí **AirRegenerationStart/End** y **AirFilterStart/End**, que el anexo no menciona. Son el valor, al inicio y al final de cada viaje, del nivel de acumulación del filtro (escala 0–100) y de los nueve niveles de mensaje del sistema que reporta la tabla de señales: coinciden con ella en el 99,8 y el 99,97 % de los pares viaje–señal. Como el significado no fue confirmado por Ford, en este informe se habla de *nivel de acumulación del filtro*.

Es saturación por uso, no desgaste. El evento ocurre con una mediana de ~ 12.800 km, dos órdenes de magnitud antes de la escala de la ceniza. Se buscó una variable de daño monótona e irreversible, que es la premisa de los modelos de degradación por procesos gamma [3], y no se encontró ninguna. Esto descartó ese enfoque y orientó el modelado hacia los hábitos de manejo y el estado reciente del filtro, en línea con la ecuación (1).

No todo “uso indebido” se sostiene. Comparando contra vehículos sanos *del mismo mercado*, lo que crece hacia el evento es el tiempo detenido con el motor en marcha y la fracción de viajes que no alcanzan la temperatura de régimen. La velocidad media y la fracción de viajes cortos no separan dentro del mercado: con la primera versión de los datos, la velocidad parecía la mejor variable y medía en realidad la diferencia entre dos países.

Lo que se propone. Un modelo secuencial que lee los últimos 1.000 km del vehículo y un circuito que convierte cada alerta en una acción. Al conductor no se le habla de fallas: se le comunican hábitos modificables, comparados con vehículos sanos de su zona.

2. Contexto del proceso

La telemetría llega a la nube de forma continua, pero la degradación se identifica una vez manifestada: en un servicio programado o cuando el cliente la reporta [1]. El desafío se ubica, por lo tanto, en la posventa, y el valor de una predicción depende de cuánto antes de esa identificación llega.

El proceso reactivo queda registrado en la telemetría. La fecha registrada del evento es posterior a la intervención en el taller. En la primera versión de los datos coincidía con ella: los cambios de aceite se concentraban en ± 3 días. En la segunda versión, la fecha de los mismos vehículos cae una mediana de 14 días más tarde, y en las dos semanas previas ya aparecen el cambio de aceite y el ralenti prolongado característico de una regeneración forzada en servicio (1,5 a 1,8 veces la tasa de base). Después del evento, además, el uso cambia: la fracción de viajes por debajo de la temperatura de régimen baja en el 72 % de los vehículos.

Ambos hechos tienen consecuencias directas sobre la formulación. Si el modelo observara los días del taller, haría la detección reactiva que Ford ya tiene. Por eso: (i) la referencia del evento es la fecha registrada menos 21 días; (ii) el modelo nunca observa los 500 km previos a esa referencia (§3.1); y (iii) ningún dato posterior al evento entra en ninguna ventana.

Dónde entra la predicción. En la posventa, la alerta alimenta un circuito que termina en una acción: un consejo de manejo al conductor cuando hay un hábito modificable que lo distingue de los vehículos sanos de su mercado, un contacto del concesionario cuando no lo hay, y un escalamiento si el riesgo se mantiene alto. La decisión es determinista y la define Ford; la redacción la hacen agentes de lenguaje bajo un verificador programado (§6).

3. Definición del desafío

Ford pide anticipar *el momento* en que un vehículo se aproxima a la degradación, con margen para actuar antes de que el cliente lo perciba [1]. Son dos exigencias que tiran en direcciones opuestas: *anticipar* obliga a no mirar los últimos kilómetros, que es donde la señal es más fuerte, y *el momento* exige información sobre *cuándo*, no solo sobre *qué vehículo*. Esta sección traduce ambas exigencias a un problema de aprendizaje supervisado y a una métrica que no se pueda satisfacer con atajos.

3.1. Formulación: panel de cortes con gap de blanking

Sea i un vehículo con historial observado hasta el odómetro L_i y, si tiene evento, E_i el odómetro en la referencia del evento (fecha registrada $- 21$ d, traducida a km con el anclaje del calendario). Se definen cortes sobre una grilla de paso Δ ,

$$c \in \{k\Delta : k \in \mathbb{N}\}, \quad c \leq \begin{cases} E_i - G & \text{si } i \text{ tiene evento,} \\ L_i - G - H & \text{si } i \text{ es sano,} \end{cases} \quad (2)$$

y para cada par (i, c) la etiqueta

$$y_{i,c} = \mathbb{K}\{G \leq E_i - c \leq G + H\}, \quad (3)$$

con $y_{i,c} = 0$ para los sanos. La condición sobre los sanos en (2) exige que el vehículo haya sido observado hasta $c + G + H$: un corte sin ese seguimiento no es un negativo verificable y se descarta (censura). La entrada del modelo es una función de los datos con odómetro en la ventana $(c - W, c]$, de modo que entre la última observación y el comienzo del horizonte siempre hay al menos G km sin información (Figura 1). Se usan

$$W = 1.000 \text{ km}, \quad G = 500 \text{ km}, \quad H = 3.000 \text{ km}, \quad \Delta = 500 \text{ km}. \quad (4)$$

Se descartan además las ventanas con menos de 5 viajes o que cubren menos de $W/2$ en km recorridos.




Figura 1: Ventana de entrada W , gap de blanking G y horizonte H alrededor de un corte c .

Elección de los parámetros. El gap G es la condición de anticipación: sin él, el modelo aprende los mensajes de “filtro sobrecargado” de los últimos kilómetros, que son la definición del evento y no un precursor. Ventanas de 2.000 y 3.000 km dieron resultados equivalentes a $W = 1.000$ km y reducen la cantidad de eventos con cortes válidos. El horizonte H ubica los positivos donde el perfil alineado al evento muestra señal (§4.5).

Eje temporal. El evento se ordena mejor por edad del vehículo que por odómetro: el desvío estándar del logaritmo del instante del evento es 0,38 en días desde la venta y 0,91 en km. Los cortes se definen en km, porque es el eje en que se acumula el uso, y la anticipación se reporta en km y en días.

Emparejamiento de los sanos. Los cortes de los vehículos sanos se muestrean con la misma distribución conjunta de odómetro (celdas de 4.000 km) y mes calendario que los cortes positivos. Sin el emparejamiento por mes, tres variables de calendario elevaban el ROC de 0,67 a 0,76; con él, de 0,57 a 0,60: el calendario dejaba de ser un atajo.

El panel de desarrollo resultante tiene 11.703 filas de 426 vehículos con cortes válidos (135 con evento) y 682 filas positivas, una tasa de 0,058.

Restricciones de validación. (i) Partición agrupada por vehículo [4]: un vehículo nunca aparece en entrenamiento y validación a la vez; los pliegues se estratifican por etiqueta, mercado y motor, y la validación cruzada de 5 pliegues se repite 3 veces. (ii) Un conjunto de prueba congelado antes de examinar cualquier variable contra la etiqueta. (iii) Variables calculadas solo hacia atrás del corte, con imputación y escalado ajustados en el entrenamiento de cada pliegue. (iv) Auditorías de fuga de información obligatorias para todo candidato (Anexo A).

3.2. Métrica de evaluación

Por qué no alcanza el PR-AUC por fila. Todas las filas positivas del panel pertenecen a vehículos con evento. Un puntaje que solo indica la cohorte, $s_{i,c} = \mathbb{1}\{i \text{ tiene evento}\}$, sin ninguna información sobre el instante, obtiene

$$\text{PR-AUC}_{\text{cohorte}} = 0,177, \quad \text{lift} = \frac{0,177}{0,058} = 3,03, \quad (5)$$

(0,263 y 2,10 con la primera versión de los datos). La meta inicial de lift, de 1,6 a 2, se alcanzaba entonces sin anticipar nada: el PR-AUC por fila [5] de este panel premia reconocer *qué vehículo* va a fallar aunque no se sepa *cuándo*, y por eso no se usó para elegir. La métrica que se usó, a continuación, exige anticipar: solo cuenta una alerta que llega antes del evento, con un presupuesto fijo de falsas alarmas. Por la misma razón no se reporta exactitud: con 5,8 % de positivos, la predicción constante “sin evento” da 94 %.

Detección por vehículo a presupuesto de falsas alarmas. Sea $s_{i,c}$ el puntaje del corte c y $c_1 < c_2 < \dots$ los cortes de i . Un vehículo queda *alertado* con umbral τ cuando su puntaje supera τ en dos cortes consecutivos, lo que equivale a

$$m_i = \max_t \min(s_{i,c_t}, s_{i,c_{t+1}}) \geq \tau. \quad (6)$$

La condición de dos cortes evita que un pico aislado cuente como alerta. Si $\mathcal{S}$ y $\mathcal{F}$ son los conjuntos de vehículos sanos y con evento, para cada presupuesto α de falsas alarmas se toma el menor umbral que lo cumple y se mide la fracción de eventos detectados:

$$\tau_\alpha = \min \left\{ \tau : \frac{1}{|\mathcal{S}|} \sum_{j \in \mathcal{S}} \mathbb{1}\{m_j \geq \tau\} \leq \alpha \right\}, \quad D(\alpha) = \frac{1}{|\mathcal{F}|} \sum_{i \in \mathcal{F}} \mathbb{1}\{m_i \geq \tau_\alpha\}. \quad (7)$$

Por construcción (2), toda alerta en un vehículo con evento ocurre al menos G km antes de E_i . El criterio primario es la detección media en cuatro presupuestos,

$$\bar{D} = \frac{1}{4} [D(0,05) + D(0,10) + D(0,15) + D(0,20)], \quad (8)$$

que pondera el rango de operación plausible para una flota.

Nulo con el historial conservado. m_i es el máximo sobre los cortes del vehículo, de modo que un historial más largo tiene más oportunidades de superar τ . Con la primera versión de los datos, los vehículos con evento tenían en promedio 18,25 cortes y los sanos 9,00, y el largo del historial como único puntaje daba lift 1,79. Por eso $D(\alpha)$ se compara con su distribución bajo la hipótesis nula, que se obtiene permutando los puntajes entre todas las filas y conservando la cantidad de cortes de cada vehículo (1.000 permutaciones). Con las bolsas asimétricas de la primera versión, ese nulo “detectaba” 10 % al 5 % de falsas alarmas.

Comparaciones. La diferencia entre dos modelos A y B se estima con un bootstrap pareado por vehículo [6]: se remuestrean vehículos con reposición, se recalcula $\bar{D}_A - \bar{D}_B$ sobre los mismos vehículos y se reporta el intervalo percentil del 95 % (1.000 réplicas). El umbral también se fija *fuera de muestra* (con los sanos de desarrollo) para medir la tasa de falsas alarmas realizada en prueba. Con unos 12 eventos por pliegue, cada candidato nuevo agrega una comparación múltiple; por eso los candidatos decisivos y sus criterios de aceptación se fijaron por escrito antes de medirlos [7].

3.3. Impacto operativo

Hoy la detección es reactiva: el aviso llega cuando el filtro ya está saturado. Para el cliente, eso es un testigo en el tablero que nadie le explicó, un vehículo que limita su potencia para protegerse y una visita al taller que no estaba en sus planes; lo que más pesa es la sensación de que nadie le avisó. Para Ford, además del costo de garantía, es un cliente que pierde confianza en la marca. Para las flotas (Ford Pro), un vehículo de trabajo en el taller es trabajo que no se hace.

El desafío menciona la satisfacción del cliente, los costos de garantía, la vida útil percibida y la planificación de los concesionarios [1]. El sistema propuesto actúa sobre ellos a través de tres palancas: el aviso llega con unos tres meses de margen (§5.1.4), en lenguaje del cliente y con una acción concreta; los casos llegan priorizados al concesionario; y el presupuesto α de la ecuación (7) es un parámetro que Ford elige según su capacidad de atención y del costo de cada aviso. La cantidad de fallas evitadas y el efecto sobre la confianza del cliente no son medibles con estos datos, y son las métricas centrales del piloto propuesto (§5.2.2).

4. Datos técnicos relevantes

4.1. Fuentes, esquema y restricciones

Se recibieron las tres tablas del anexo de datos [1] (estática del vehículo, resúmenes de viaje *TripSummary* y señales *DynamicInformation*), cada una dividida en dos cohortes (vehículos con y sin evento) y en dos versiones. La segunda versión de los datos trajo una tabla estática nueva, con ciudad de venta y país, y nuevos viajes y señales de los vehículos con evento; los de los sanos son idénticos byte a byte a los de la primera. En total son $\sim 2,5 \times 10^6$ viajes y $\sim 10^7$ señales.

Contraste con el diccionario. *TripSummary* trae 25 de las 40 columnas documentadas: faltan posición GPS, elevación, presión de neumáticos, hollín de regeneración manual y autonomía. Las columnas del DPF llegan con otra denominación (§1). No hay VIN: la clave es un código anonimizado, y la unión de las tres tablas es completa. El evento no está marcado fila a fila: la fecha del evento existe en el 100 % de los vehículos de la cohorte con evento y en ninguno de la otra. *La cohorte es la etiqueta*, y por lo tanto nunca se usa como variable. El historial alcanza holgadamente para ventanas de varios miles de km (mediana de ~ 2.000 viajes y más de un año por vehículo).

4.2. Calidad de datos: sesgos, limpieza, faltantes y atípicos

Los problemas de la Tabla 1 tienen algo en común: ninguno produce un error de ejecución, y todos producen una métrica mejor de lo que corresponde. Cada corrección se aplica al leer los archivos, se declara en un archivo de configuración y tiene un test automático.

Tabla 1: Problemas encontrados en los datos, evidencia y tratamiento.

Problema	Evidencia	Tratamiento
<i>Muestreo y etiqueta</i>		
Cohortes muestreadas en períodos de producción distintos	Antes del 20-01-2025 solo hay vehículos con evento (92) y después de julio de 2025 solo sanos (341, con ~ 50 eventos esperados). Con ellos, la fecha de producción sola separa las cohortes con AUC 0,87 dentro del mercado	Universo restringido al período común (§4.3)
Fecha registrada posterior al taller	Cambio de aceite y ralentí prolongado en las dos semanas previas	Referencia del evento = fecha – 21 d
Tasa de eventos por país dependiente de la extracción	De 0 % (PER) a 48 % (COL), en orden inverso a la cantidad de vehículos con evento sin fecha excluidos por mercado	Toda comparación entre cohortes, dentro del mercado
13 vehículos con dos códigos	Mismos viajes bajo dos identificadores (Jaccard 1,0 sobre fecha y odómetro)	Se unifican antes de particionar
Formato de la segunda versión	Columna del evento renombrada; fecha de producción con otro origen (+538 d); una fila por evento; filas repetidas; extracción de la cohorte con evento diez días más larga (16.911 viajes)	Corrección al leer y corte en el fin de extracción común (14-09-2026)
Cambio de uso posterior al evento	Viajes bajo régimen: bajan en el 72 % de los vehículos; velocidad: sube en el 79 %	Ningún dato posterior al evento entra en una ventana
<i>Columnas, faltantes y atípicos</i>		
Contador de regeneraciones interrumpido	Cero registros desde el 25-05-2026 en toda la flota; su correlación con la etiqueta (0,317) era calendario	Solo para auditoría; regeneración = caída de la acumulación, ec. (9)
Velocidad imposible o nula	Hasta $1,36 \times 10^5$ km/h; nula <i>exactamente</i> en los viajes de 0 km (33 % de las filas)	Recalculada como km/duración con tope de 200 km/h; el ralentí es una variable, no un faltante
Temperaturas, duraciones y km extremos	-73°C , viajes de 20 días y de -230 km ($< 0,05$ % cada uno)	Topes físicos fijos; viajes con km negativos o sin odómetro, descartados
Columnas con otra semántica	Combustible > 100 en el 10,5 % de los viajes; vida del aceite constante dentro del viaje; acumulación hasta 100	Combustible como índice relativo; pendiente del aceite en la ventana; saturación = nivel ≥ 95
Fechas en dos formatos	Sin declararlo, el parser anulaba 4.464 inicios de viaje y 18.124 señales	Formato ISO 8601 explícito
Odómetro de señales nulo	11 % en la primera versión de los datos (9 vehículos); 0,5 % en la segunda	La ventana se ubica con el odómetro de los viajes
Tramos sin viajes	Huecos de 50 km en la secuencia	Canal de cobertura y arrastre del último valor

La imputación (mediana) y el escalado se ajustan en el entrenamiento de cada pliegue. Queda una pregunta que solo Ford puede responder: entre las dos versiones de los datos salieron 278 vehículos con evento y fecha por defecto, concentrados por mercado; no se sabe si son eventos sin fecha o un error de extracción, y eso explica en parte la variación de la tasa entre países.




Figura 2: Del conjunto recibido al conjunto de prueba. La partición se sorteó al recibir la segunda versión de los datos (semilla 42, estratificada por evento, mercado y motor), antes de examinar ninguna de sus variables contra la etiqueta. Se recibió además un vehículo de Paraguay, mercado sin vehículos sanos, que no entra en el estudio.

4.3. Universo de estudio y partición

Se conserva el período de producción en que se muestrearon ambas cohortes: un vehículo sano producido en octubre de 2025 no es un negativo verificable si de esa época no se registró ningún evento. Se evaluó también la alternativa de incluir los 433 vehículos excluidos: con ellos, los modelos ordenaban *peor* a los vehículos comparables, porque aprendían la fecha de producción. Con la segunda versión de los datos la partición se volvió a sortear sobre el universo nuevo.

Esa versión modificó varias conclusiones: la velocidad dejó de separar dentro del mercado; apareció una trayectoria hacia el evento que antes no se observaba; la ventana de calendario del registro de eventos resultó ser propia de la extracción anterior; y el motor ENG_3, sin eventos en la primera versión, pasó a tener 47 (46 en Brasil).

4.4. Ingeniería de variables

Variables derivadas por viaje. Sobre cada viaje j con distancia d_j y duración δ_j se calcula, entre otras, la velocidad $v_j = d_j/\delta_j$ (con tope de 200 km/h), el indicador de ralentí $\mathbb{K}\{d_j = 0\}$, el de motor bajo régimen $\mathbb{K}\{T_{\text{máx},j}^{\text{motor}} < 70 \text{ °C}\}$ entre los viajes con desplazamiento, y el arranque en frío. Las fracciones “de viaje” se calculan solo entre los viajes con $d_j > 0$. Como el contador de regeneraciones deja de reportar, una regeneración se define a partir del nivel de acumulación a :

$$r_j = \mathbb{K}\{a_j^{\text{inicio}} - a_j^{\text{fin}} > 15\}, \quad (9)$$

es decir, una caída de más de 15 puntos entre el inicio y el final del viaje. Con un umbral de 5 puntos, el saldo acumulado de subidas y caídas no seguía la acumulación (correlación 0,005 contra 0,45): el umbral bajo contaba ruido.

Representación agregada. Para los modelos tabulares y de supervivencia, la ventana se resume en 53 variables

$$x_{i,c}^{(f)} = \text{agg}_f(\{z_j^{(f)} : j \in i, \text{odo}_j \in (c - W, c]\}), \quad (10)$$

donde $z^{(f)}$ es una variable derivada y agg_f un agregador: media, mediana, percentil, conteo por 1.000 km o por día, distancia media entre eventos, km desde el último evento, y tendencia como diferencia entre la segunda y la primera mitad de la ventana. Se agrupan en cuatro familias: térmica y trayectos cortos (17), regeneración (15), uso (6) y severidad de mensajes (13), más dos de control de cobertura (Anexo C).

Representación secuencial. Para los modelos recurrentes, la ventana se divide en $T = 20$ tramos de 50 km y en cada tramo t se calculan $C = 15$ canales, lo que da un tensor

$$\mathbf{X}_{i,c} \in \mathbb{R}^{T \times C}, \quad \mathbf{X}_{i,c}[t,k] = \text{agg}_k(\{z_j^{(k)} : \text{odo}_j \in (c - W + 50(t - 1), c - W + 50t]\}). \quad (11)$$

Seis canales describen cómo se viaja (cantidad de viajes, ralentí, bajo régimen, velocidad, km y duración por viaje) y nueve el estado del filtro (acumulación media y máxima, subida de la acumulación, regeneraciones, tres fracciones de mensajes, registros y cobertura). Un tramo sin datos se rellena con cero en los conteos y con el último valor de la ventana en los niveles; el canal de cobertura indica al modelo cuál es cuál. Se agregan país, motor y serie como variables estáticas.

Variables excluidas del modelo. Se conservan solo para auditoría las que miden calendario o cohorte y no el vehículo: fechas de producción y de venta, temperatura ambiente (los vehículos con evento circulan en zonas más frías que los sanos de su mercado) y el contador de regeneraciones interrumpido.

4.5. Análisis exploratorio

Todo el análisis se hizo sobre el conjunto de desarrollo y compara contra sanos *del mismo mercado*: con cinco mercados de tasas muy distintas, una comparación agrupada confunde país con vehículo. Para una variable x y una distancia al evento d , se estima

$$\theta(d) = P(x_{\mathcal{F}} > x_{\mathcal{S}} \mid \text{mismo mercado y tramo de odómetro, } E - c \in d), \quad (12)$$

la probabilidad de que un corte de un vehículo con evento supere a uno sano comparable ($\theta = 0,5$: sin separación).




Figura 3: Probabilidad $\theta(d)$ de la ecuación (12) para cuatro variables, según la distancia al evento.

La Figura 3 muestra que la huella crece hacia el evento: la fracción de ralentí pasa de $\theta = 0,60$ a 0,64 y 0,76, y la de viajes bajo régimen de 0,55 a 0,62 y 0,73, mientras la temperatura del refrigerante al final del viaje baja (θ de 0,47 a 0,29) y la velocidad no se aparta de 0,5. Lo que crece es el tiempo detenido con el motor en marcha y la imposibilidad de alcanzar temperatura, consistente con la ecuación (1); lejos del evento la señal es débil. La señal también aparece temprano: con los primeros 60 días de uso tras la venta, el ralentí ordena vehículos con AUC 0,636 dentro del mercado, que es información de *qué vehículo*. Por último, el riesgo es función de la edad y no del odómetro: la tasa de eventos crece hasta los ~ 4 meses desde la venta y luego se estabiliza en 3 a 4 eventos cada 100 vehículos-mes, sin efecto del mes calendario ($p = 0,16$).

5. Expectativas de solución

La solución combina los cuatro campos que menciona el desafío [1]: análisis de datos (§4), aprendizaje automático (modelos lineales, *gradient boosting* y supervivencia en tiempo discreto

con validación agrupada), aprendizaje profundo (el modelo finalista es una red recurrente con atención) e IA generativa (agentes que redactan los avisos bajo un verificador programado, §6).

5.1. Objetivo de mejora: anticipar con el mayor margen posible

5.1.1. Modelos evaluados

Todos los candidatos se entrenaron sobre el mismo panel, con los mismos pliegues, y se evaluaron con la métrica (8). Las familias principales fueron:

- **Modelos tabulares** sobre las 53 variables agregadas (10): regresión logística con regularización L2 y L1, y LightGBM [8].
- **Supervivencia en tiempo discreto** (*survival stacking* [9, 10]): cada fila se replica en B tramos de km del horizonte y un clasificador estima el riesgo condicional por tramo,

$$h_b(\mathbf{x}) = P(E - c \in I_b \mid E - c > I_{b-1}, \mathbf{x}), \quad s(\mathbf{x}) = 1 - \prod_{b=1}^B (1 - h_b(\mathbf{x})), \quad (13)$$

donde s es la probabilidad de evento dentro del horizonte. Usa la información de los cortes censurados que la clasificación binaria descarta. Se probó también con un efecto aleatorio por vehículo.

- **Modelos secuenciales** sobre el tensor (11): GRU con atención [11, 12] y MiniRocket [13].
- **Alternativas descartadas:** proceso gamma de degradación [3] (no hay variable de daño irreversible, §1) y pronóstico de series con el modelo fundacional TimesFM [14] sin ajuste.

Con la primera versión de los datos (290 vehículos de desarrollo y dos mercados), los modelos tabulares aprendían *qué vehículo* y no *cuándo*, lo que motivó la métrica de la §3.2. Con la segunda versión (446 vehículos y el triple de eventos), los modelos secuenciales pasaron adelante. Sobre 42 configuraciones medidas con la misma métrica en desarrollo [*dev*], la GRU con viajes y variables estáticas, en un ensamble de tres semillas, detecta 27, 42 y 61 % de los eventos al 5, 10 y 20 % de falsas alarmas, contra 14, 24 y 42 % de survival stacking. Una búsqueda bayesiana de 130 ensayos sobre sus hiperparámetros (Optuna [15]) no mejoró la configuración base cuando se la volvió a medir con semillas nuevas ($\bar{D}$ de 46,9 contra 47,1): la variación entre semillas es mayor que la de los hiperparámetros, y por eso el finalista es un ensamble de tres semillas. TimesFM y MiniRocket no mejoraron a la GRU en desarrollo.

5.1.2. Arquitectura del modelo finalista

El finalista es una red GRU unidireccional con atención y una rama estática de fusión tardía (Figura 4). Para cada corte, la red recibe la secuencia $\mathbf{x}_1, \dots, \mathbf{x}_T \in \mathbb{R}^C$ (las filas de $\mathbf{X}_{i,c}$, estandarizadas con el entrenamiento del pliegue) y actualiza un estado oculto $\mathbf{h}_t \in \mathbb{R}^d$, $d = 24$, mediante las compuertas de actualización $\mathbf{z}_t$ y de reinicio $\mathbf{r}_t$ [11]:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z), \quad (14)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r), \quad (15)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h), \quad (16)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (17)$$

La compuerta $\mathbf{z}_t$ decide qué parte del estado se reemplaza con la información del tramo y $\mathbf{r}_t$ cuánto del pasado se usa para calcularla. Esto permite representar tendencias que un agregado (10) pierde, como una acumulación que sube de forma sostenida o viajes que se acortan. La red es unidireccional porque el eje es kilómetros recorridos: un estado en el km 200 de la ventana no debe depender del km 900.

Los estados se resumen con una atención aditiva de una cabeza [12],

$$e_t = \mathbf{v}^\top \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a), \quad \alpha_t = \frac{\exp e_t}{\sum_{t'} \exp e_{t'}}, \quad \mathbf{h}^* = \sum_{t=1}^T \alpha_t \mathbf{h}_t, \quad (18)$$

con $\mathbf{W}_a \in \mathbb{R}^{16 \times d}$, que puede tomar directamente un tramo intermedio de la ventana sin arrastrarlo por todos los siguientes. Las variables estáticas $\mathbf{s}$ (país, motor y serie en codificación *one-hot*) pasan por una capa $\mathbf{u} = \text{ReLU}(\mathbf{W}_s \mathbf{s} + \mathbf{b}_s) \in \mathbb{R}^4$, y la cabeza produce el puntaje

$$\hat{p}_{i,c} = \sigma(\mathbf{w}_2^\top \text{ReLU}(\mathbf{W}_1[\mathbf{h}^*; \mathbf{u}] + \mathbf{b}_1) + b_2), \quad \mathbf{W}_1 \in \mathbb{R}^{16 \times 28}. \quad (19)$$

El total es de 3.901 parámetros: 2.952 en la GRU, 416 en la atención, 52 en la rama estática y 481 en la cabeza.




Figura 4: Arquitectura del modelo finalista.

Entrenamiento. Se minimiza la entropía cruzada binaria ponderada sobre las ~ 11.700 filas de desarrollo,

$$\mathcal{L} = -\frac{1}{N} \sum_{(i,c)} \left[w_+ y_{i,c} \log \hat{p}_{i,c} + (1 - y_{i,c}) \log(1 - \hat{p}_{i,c}) \right], \quad w_+ = \frac{N_-}{N_+}, \quad (20)$$

donde N_+ y N_- son las filas positivas y negativas del entrenamiento de cada pliegue (no se remuestrea). Se usa Adam [16] con tasa de aprendizaje 10^{-3} , decaimiento de pesos 10^{-4} , lotes de 64, recorte de gradiente en norma 1, *dropout* de 0,3 y 40 épocas fijas. No hay detención temprana porque una validación interna por filas mezclaría cortes del mismo vehículo. La red es pequeña a propósito: con 135 vehículos con evento, una red grande memoriza vehículos en lugar de hábitos.

Ensamble. Como la variación entre semillas supera a la de los hiperparámetros (§5.1.1), el puntaje final promedia los rangos percentiles de tres redes entrenadas con las semillas 42, 1 y 2 (fijadas de antemano, no elegidas por resultado):

$$s_{i,c} = \frac{1}{3} \sum_{k=1}^3 \text{rk}(\hat{p}_{i,c}^{(k)}), \quad \text{rk}(p) = \frac{\#\{(i',c') : \hat{p}_{i',c'}^{(k)} \leq p\}}{N}. \quad (21)$$

El rango hace comparables escalas distintas y no modifica la métrica (7), que solo depende del orden. El puntaje resultante ordena vehículos y no es una probabilidad calibrada: la pérdida (20) pondera los positivos y el ensamble promedia rangos. Por eso las alertas se fijan con un presupuesto de falsas alarmas (7) y no con un umbral de probabilidad.

5.1.3. Resultados en el conjunto de prueba

El conjunto de prueba son los 111 vehículos separados en la §4.3, de los cuales 103 tienen cortes válidos (32 con evento y 71 sanos). Cada modelo se entrenó con todo el conjunto de desarrollo y se evaluó con la misma métrica. La Figura 5 muestra $D(\alpha)$ para todo el rango de presupuestos y la Tabla 2 resume los valores principales.




Figura 5: Detección $D(\alpha)$ según el presupuesto de falsas alarmas α en el conjunto de prueba $[test]$. La banda gris es la distribución nula, ec. (7) con puntajes permutados, hasta su percentil 95.

Tabla 2: Detección $D(\alpha)$ (%) del modelo finalista en el conjunto de prueba $[test]$. $\bar{D}$ según la ec. (8).

	$\alpha = 5\%$	10%	15%	20%	$\bar{D}$
GRU, ensamble de 3 semillas	31,2	46,9	62,5	62,5	50,8
Survival stacking	18,8	21,9	21,9	43,8	26,6
Nulo: media / percentil 95	7,0 / 15,6	13,7 / 25,0	18,6 / 31,2	24,4 / 40,6	–

- Al 5 % de falsas alarmas se detectan 10 de 32 eventos: 4,5 veces la media del nulo y por encima de su percentil 95. Al 20 %, seis de cada diez.
- $\bar{D}$ duplica al de los modelos tabulares y de supervivencia (50,8 contra 21–27; frente a survival stacking, +24,2 puntos, IC [0,8; 43,0]).
- **Umbral fijado fuera de muestra.** Con τ_α calculado con los sanos de desarrollo, la detección en prueba es de 20, 34 y 57 % al 5, 10 y 20 %, con tasas de falsas alarmas realizadas de 5,8, 8,9 y 18,2 %: el umbral respeta su presupuesto en vehículos nuevos.
- El resultado es consistente con el de desarrollo (27,4 · 42,5 · 53,3 · 60,7 %, $\bar{D} = 46,0$), y el AUC por vehículo en prueba es 0,794.

Incertidumbre. Tres entrenamientos de la misma configuración, evaluados en prueba, dieron 34, 28 y 31 % al 5 %: el entrenamiento de la GRU no es determinista entre ejecuciones, y con 32 eventos cada vehículo representa 3 puntos. Por eso el resultado se reporta como rango: $\sim 30\%$ al 5 %, $\sim 40\text{--}50\%$ al 10 % y $\sim 50\text{--}60\%$ al 20 %.

5.1.4. Anticipación

Para cada vehículo detectado se mide la distancia entre la primera alerta sostenida (6) y la referencia del evento, $\ell_i = E_i - c_i^*$, donde c_i^* es el primero de los dos cortes consecutivos sobre τ_α . Por la ecuación (2), $\ell_i \geq G$.




Figura 6: Rango percentil medio del puntaje en los cortes sanos y en los cortes de vehículos con evento, según la distancia al evento [test].

Al 10 % de falsas alarmas, la mediana de ℓ_i en prueba es de **4.646 km** (rango intercuartil 2.403–9.263 km), unos 99 días; al 5 %, 3.987 km (~ 72 días), y al 20 %, 5.969 km (~ 109 días). En desarrollo la mediana es de ~ 7.600 km (~ 86 días): los vehículos detectados en prueba recorren menos km por día, y en días el margen es similar. La Figura 6 muestra que el puntaje crece hacia el evento (rango medio 0,58 a más de 10.000 km, 0,61 entre 3.500 y 10.000 km y 0,72 a menos de 3.500 km, contra 0,44 en los sanos), pero con una dispersión grande. La salida del modelo es, por lo tanto, un *margen* de anticipación y no un pronóstico del instante de falla.

5.2. Criterios de evaluación

5.2.1. Viabilidad técnica

El sistema no requiere sensores nuevos: usa los resúmenes de viaje y los mensajes del filtro que el vehículo ya transmite. La red tiene ~ 3.900 parámetros y corre en CPU (las 56 corridas de la evaluación completa en desarrollo tardaron ~ 25 minutos en 24 núcleos), y el mismo código de variables se usa en entrenamiento y en producción. Para un millón de vehículos se estima un proceso diario de 1 a 2 horas en 8 a 16 vCPU, a validar con Ford: la red puntúa en milisegundos por vehículo y no necesita GPU ni para servir ni para reentrenar. Los agentes de lenguaje trabajan solo sobre las alertas, de modo que el costo de la IA generativa crece con los avisos y no con la flota. El circuito de posventa y el prototipo que lo implementa se describen en la §6; la Tabla 3 resume el camino a producción.

La etapa en sombra es la central: es la primera medición de la prevalencia real y de las falsas alarmas sobre la flota completa, y no sobre las listas extraídas para el desafío. El monitoreo sigue la tasa de alertas por mercado, la deriva de las variables de entrada, la detección realizada y la interrupción de fuentes de datos (como ocurrió con el contador de regeneraciones). El reentrenamiento es trimestral, con las mismas auditorías.

Empaquetado. El paquete que se propone para producción contiene todo lo necesario para puntuar igual que en la evaluación: los pesos de cada semilla, exportados a ONNX para servir sin el entorno de entrenamiento; la imputación y el escalado ajustados; la distribución de puntajes de los vehículos sanos de entrenamiento, sin la cual el ensamble por rango (21) no puede calcularse para un vehículo aislado; los umbrales τ_α por presupuesto; y un manifiesto con la configuración, el orden de las variables y las versiones de las bibliotecas. Al cargarlo, 20 vehículos de control se vuelven a puntuar y deben reproducir su puntaje. El paquete se versiona y avanza por etapas:

Tabla 3: Etapas de implementación.

Etapa	Alcance	Duración	Criterio para avanzar
0. Congelamiento	Reentrenar con los 557 vehículos y empaquetar pesos, umbrales y referencia del ensamble	1–2 semanas	Reproduce el puntaje de 20 vehículos de control
1. Sombra	Puntuar la flota real de un mercado sin emitir avisos	3–6 meses	Tasa de alertas $\approx \alpha$; detección realizada medida
2. Piloto activo	Avisos en una región, con grupo de control	6 meses	Fallas evitadas, costo por alerta, cambio de hábitos
3. Escala	Mercados validados, umbral por mercado	continuo	Monitoreo dentro de tolerancia

candidato, sombra y producción. La Tabla 4 resume los riesgos de operación y cómo se mitigan.

Tabla 4: Riesgos de operación y mitigación.

Riesgo	Mitigación
Prevalencia real distinta de la del estudio	El umbral se recalibra en la etapa en sombra; no se hereda del desarrollo
Fatiga de alertas	Empezar con $\alpha = 5\%$; avisar al conductor solo con un hábito para nombrar; escalar solo si el riesgo sigue alto
Cambio de <i>firmware</i> o de telemetría	Monitoreo de columnas nulas o interrumpidas por mercado
Privacidad	Solo agregados por viaje que Ford ya procesa, sin ubicación
Mercados sin eventos registrados (PER)	El sistema no se activa donde no se validó
Motores o modelos nuevos	No se activan hasta tener eventos propios
Cambio de versión del modelo de lenguaje	Versión fijada; todo texto pasa igual por el verificador y, si falla, se usa una plantilla aprobada
Vehículo nuevo, sin historial	Necesita 1.000 km recorridos para su primer puntaje

5.2.2. Costo y valor

Lo que pierde el cliente. La reparación tiene un precio que Ford conoce mejor que nadie, pero el costo principal de una falla sin aviso no está en la factura: una visita al taller que el cliente no planeaba, días sin el vehículo y, sobre todo, la confianza. Un cliente que se entera tarde se pregunta si su Ford lo cuida; cada falla sin aviso se paga en confianza y, en una flota de trabajo, en días de operación perdidos.

Lo que cuesta avisar. Con la telemetría que Ford ya recibe, operar el sistema para un millón de vehículos cuesta del orden de USD 0,10 por vehículo y por año (Tabla 5). El 80 % del costo es la persona que lo opera, de modo que el costo marginal por vehículo es muy bajo. La implementación se estima en USD 70.000–110.000 por única vez, incluida la etapa en sombra.

La balanza. La pregunta, entonces, no es cuánto cuesta avisar sino cuántos avisos soporta la confianza de un cliente. En un platillo está el aviso de menos: la falla que llega sin aviso. En el otro, el aviso de más: un mensaje que no hacía falta. El sistema está diseñado para que el aviso de más pese lo menos posible: el primer contacto es un consejo de manejo y no un turno en el taller, y si el vehículo no iba a fallar, el conductor recibió un consejo que igual le hace bien al motor. En el prototipo, al 5 % de falsas alarmas, 48 de las 53 alertas (91 %) son un consejo [*dev*]; el concesionario interviene solo si no hay un hábito para nombrar o si el riesgo se mantiene. El punto de equilibrio lo elige Ford con α : al 5 %, uno de cada veinte vehículos sanos recibe un consejo de más y se avisa a casi uno de cada tres eventos; al 20 %, a seis de cada diez, con cuatro

Tabla 5: Costo anual de operación estimado para un millón de vehículos (a validar con Ford).

Componente	USD por año	Supuesto
Variables y puntaje diario	2.500–6.000	proceso de 1–2 h en 8–16 vCPU
Agentes de lenguaje	1.000–3.000	~ 65.000 alertas por año, modelo pequeño
Reentrenamiento y monitoreo	5.000–10.000	trimestral, en CPU
Equipo de operación	60.000–80.000	1 persona de ML/MLOps
Total	~70.000–100.000	USD 0,07–0,10 por vehículo y año

veces más consejos de más *[test]*.

En una flota real, además, la mayoría de los avisos irán a vehículos que no iban a fallar. Con una prevalencia π , el valor predictivo positivo es

$$\text{VPP} = \frac{\pi D(\alpha)}{\pi D(\alpha) + (1 - \pi) \alpha}, \quad (22)$$

que con $\pi = 5\%$, $\alpha = 5\%$ y $D = 30\%$ da $\sim 0,24$: unos 2 de cada 10 avisos corresponden a un vehículo que iba a fallar. Por eso el primer contacto tiene que servirle a cualquier conductor, y el umbral se recalibra con la prevalencia real en la etapa en sombra.

Por qué no enviar el consejo a toda la flota. Si avisar no costara nada, avisar a todos le ganaría a cualquier modelo. No es así por tres razones. Un consejo genérico se ignora, y cada aviso de más gasta la credibilidad del siguiente. Lo que vale es la personalización: “comparado con vehículos sanos de tu zona, tu camioneta hace muchos viajes cortos” solo se puede decir si es cierto para ese vehículo. Y el segundo paso, el contacto del concesionario, sí tiene un costo: el modelo decide a quién llamar.

Lo que mide el piloto. No se reporta un ahorro: el costo de una falla para Ford no se conoce, y la pérdida de consumo asociada a la saturación no se pudo medir con estos datos. El piloto activo, con un grupo que recibe avisos y otro de control, mide: la confianza (satisfacción y reclamos), la fricción (apertura de los avisos y bajas de las notificaciones), la retención en la red de servicio, el cambio del hábito recomendado (visible en la misma telemetría), las averías y el consumo (modos de protección, visitas no planificadas y combustible) y el costo por alerta y por falla evitada, ya con los costos reales de Ford.

5.2.3. Carácter innovador

1. **Anticipa de verdad.** El modelo nunca observa los 500 km previos al evento y aun así avisa con una mediana de ~ 4.600 km, unos tres meses (§5.1.4). Se evalúa con una métrica que exige anticipar (detección por vehículo a presupuesto de falsas alarmas (7)) en lugar de un PR-AUC por fila que premia reconocer el vehículo. Una red que lee la ventana en orden (14)–(18) duplica en prueba la detección de los modelos tabulares y de supervivencia.
2. **No exagera.** Cada número se presenta junto a un nulo que conserva el largo del historial; el resultado se mide en un conjunto de prueba que nunca se usó para entrenar ni para ajustar; los criterios de aceptación se fijaron por escrito antes de medir, y todo candidato pasa auditorías de fuga de información (Anexo A).
3. **Habla como una persona, sin inventar.** El modelo decide si hay alerta, una política determinista elige la acción, un agente de lenguaje redacta y el código verifica: el modelo de lenguaje nunca produce un número ni un diagnóstico. La explicación al conductor es una comparación con vehículos sanos, no una causa (§6).
4. **No toca ni un auto, y el dial es de Ford.** Usa solo la telemetría que el vehículo ya transmite, sin sensores nuevos, corre en CPU y su costo marginal por vehículo es mínimo. El presupuesto α es un parámetro operativo que Ford elige según lo que le cuesta cada aviso.

5.2.4. Calidad del tratamiento de datos y trazabilidad

Los problemas de la §4.2 se corrigen al leer los archivos crudos, y cada corrección está declarada en un único archivo de configuración y cubierta por un chequeo automático. El proceso es reproducible de punta a punta: la unión de las tablas, la unificación de duplicados, el universo de estudio, la partición (congelada en un archivo con la lista de vehículos de cada conjunto), el panel y las variables se reconstruyen desde los datos crudos de forma determinista, con parámetros que salen de archivos de configuración y nunca del código. Cada experimento está definido por un archivo de configuración versionado (variables, semillas e hiperparámetros) y sus métricas se registran junto con esa configuración; el panel y la partición se publican como artefactos versionados. Las variables se calculan solo hacia atrás del corte, la imputación y el escalado se ajustan dentro de cada pliegue, y un chequeo automático de más de 200 verificaciones corre antes de integrar cualquier cambio.

5.2.5. Explicabilidad del modelo

Importancia por permutación. Para medir en qué se apoya la GRU se permuta cada canal k entre los cortes de validación, moviendo sus T tramos juntos para conservar la forma de la serie, y se mide la caída del criterio primario [17]:

$$I_k = \bar{D} - \bar{D}(\mathbf{X}^{\pi_k}), \quad (23)$$

donde $\mathbf{X}^{\pi_k}$ es el tensor con el canal k permutado. Las variables estáticas se tratan igual. Las caídas no son aditivas, porque los canales están correlacionados.




Figura 7: Importancia por permutación I_k , ec. (23), en puntos de $\bar{D}$ [dev], sobre una base de 51,9 %.

El hábito de mayor peso es la duración de los viajes ($I = -24,1$ puntos), seguido de km por viaje, velocidad, motor bajo régimen y ralentí (Figura 7). Del estado del filtro, la variable principal es la subida de la acumulación ($-22,2$). El país pesa más que cualquier señal individual ($-28,1$): el riesgo de base no es el mismo en todos los mercados. El patrón coincide con la física de la ecuación (1) (viajes cortos que no completan la regeneración y hollín que se acumula), sin que se le haya provisto al modelo ninguna regla del filtro.

Explicación al conductor. La GRU no ofrece una atribución confiable por vehículo, y 7 de sus 15 canales describen el estado del propio filtro, que el conductor no controla. Por eso la explicación que se comunica es una comparación: los hábitos (hasta tres) en los que el vehículo supera al percentil 75 de los sanos de su mercado, restringidos a los modificables cuyo efecto coincide con la física del DPF. Los síntomas y el contexto se informan solo al taller, y el texto al conductor dice “comparado con vehículos sanos de su zona”, nunca “porque” (§6).

6. Producto: de la alerta a la acción

Una alerta sola no evita ninguna falla: la evita que alguien haga algo a tiempo. El producto convierte cada alerta en una acción —un consejo de manejo al conductor o un contacto del concesionario— redactada por agentes de IA generativa y controlada por código. Lo ordena un principio: *el modelo decide, el agente comunica y el código cuida lo que se dice*. El modelo de lenguaje nunca produce un puntaje, un número ni un diagnóstico: solo redacta a partir de los hechos que el sistema le entrega.

6.1. El circuito




Figura 8: Circuito de posventa. El modelo decide si hay alerta, la política (recuadro punteado) decide la acción y los agentes solo redactan.

El circuito de la Figura 8 tiene siete pasos:

1. **Telemetría diaria** del vehículo conectado: los resúmenes de viaje y los mensajes del filtro que Ford ya recibe.
2. **Puntaje** de la GRU cada 500 km, sobre los últimos 1.000 km (§5.1.2).
3. **Alerta confirmada** cuando el puntaje supera dos veces seguidas el umbral τ_α (6), con el presupuesto α que eligió Ford.
4. **El porqué**: los hábitos en los que el vehículo supera al percentil 75 de los vehículos sanos de su mercado, solo los modificables y coherentes con la física del DPF, hasta tres (§5.2.5).
5. **Política determinista**, que define Ford: si hay un hábito para nombrar, se envía un consejo al conductor; si no lo hay, lo contacta el concesionario; si el riesgo sigue alto dos revisiones después (una revisión es un corte, cada 500 km), el caso se escala al concesionario.
6. **Redacción**: los agentes escriben los textos y un verificador programado los controla.
7. **Retorno del taller**: cada intervención registrada indica si hubo alerta antes y con cuánto margen, y alimenta el monitoreo y el reentrenamiento.

6.2. Agentes y verificador

La Tabla 6 resume las tres piezas. Los agentes trabajan solo sobre las alertas, no sobre la flota, y ninguno puede cambiar la acción que fija la política.

Cada pedido al modelo de lenguaje se guarda con una clave derivada de lo que lo define, de modo que un texto aprobado no cambia entre ejecuciones y el prototipo se reproduce sin conexión.

6.3. Tres destinatarios, tres mensajes

- **El conductor**, en la aplicación de su Ford, recibe un hábito concreto, algo que puede hacer el fin de semana, sin códigos de error, sin porcentajes y sin hablar de fallas. Por ejemplo: *“Comparado con autos sanos de tu zona, tu camioneta hace muchos viajes cortos. Un tramo de ruta de 20 minutos por semana ayuda a que el filtro se limpie solo.”*
- **El concesionario** recibe la ficha del vehículo, con las señales del filtro comparadas con las de los vehículos sanos de su mercado y los chequeos sugeridos.

Tabla 6: Las piezas que redactan y controlan los textos.

Pieza	Qué hace
Agente de clasificación	Recorre los eventos de la semana con herramientas: consulta la acción que fija la política y el contexto de la flota, encarga la redacción y arma el resumen semanal para posventa. No puede elegir una acción distinta de la política.
Agente redactor	Escribe el mensaje al conductor, el resumen para el taller y la línea de la bandeja de posventa. Las recomendaciones y los chequeos se eligen de listas cerradas, y su texto lo pone el código.
Verificador (código)	Todo número tiene que estar en los hechos del caso. Rechaza el lenguaje causal (“porque”, “debido a”), las certezas, las promesas de que el riesgo baja, la palabra “probabilidad” y las atribuciones (“el sistema lo marcó por...”, “se parece a autos que fallaron”). Al conductor no le llegan síntomas del filtro (carga, regeneraciones, aceite, consumo). Si rechaza un texto, el agente lo reintenta hasta dos veces con la lista de problemas; si no lo logra, se usa una plantilla aprobada.

- **Posventa de Ford** recibe cada lunes una bandeja con las alertas de la semana priorizadas y ya redactadas, para aprobar o editar.

6.4. Prototipo

Se construyó una aplicación que reproduce semana a semana los 426 vehículos de desarrollo con el modelo finalista: en cada semana el sistema solo conoce lo que se sabía ese día, y ningún vehículo del conjunto de prueba aparece en ella. Tiene tres vistas —la bandeja de posventa, la ficha del vehículo y el seguimiento de lo que pasó después— y un control del presupuesto α (Tabla 7). El acceso está en la §7.

Tabla 7: La temporada reproducida en el prototipo, según el presupuesto de falsas alarmas [*dev*] (426 vehículos: 135 con evento y 291 sanos).

	$\alpha = 5\%$	10 %	15 %	20 %
Vehículos con evento avisados antes (de 135)	39	56	69	82
Vehículos sanos con un aviso de más (de 291)	14	29	43	58
Alertas nuevas / escalamientos	53 / 7	85 / 10	112 / 22	140 / 36
Alertas con un hábito para nombrar	48	73	101	125
Anticipación mediana, semanas (km)	15 (7.000)	16 (7.200)	16 (7.500)	21 (8.100)

Al 5 %, 39 de los 135 vehículos con evento reciben un aviso con una mediana de 15 semanas de margen, y 14 de los 291 sanos reciben uno de más; 48 de las 53 alertas son un consejo al conductor. La muestra está enriquecida en eventos (135 de 426), de modo que los conteos no se trasladan directamente a una flota real (§5.2.2). En los cuatro puntos del control, los agentes redactaron 465 textos y 196 resúmenes semanales, todos aprobados por el verificador, que rechazó 103 intentos en el camino; no hizo falta ninguna plantilla.

7. Información complementaria

Documentación utilizada. El conjunto de datos y su diccionario se recibieron en dos versiones, y el diccionario se contrastó con los archivos columna por columna (§4). Cada hallazgo, decisión y experimento quedó documentado con su fecha, su motivo y el procedimiento que lo reproduce, y cada experimento está definido por un archivo de configuración versionado.

Prototipo. La aplicación de la §6.4 está disponible en línea, con acceso por clave:



<https://scan.page/Jr0sm5>

Información que solo Ford puede aportar. El límite actual no es el modelo sino la información disponible:

1. **La tasa real de eventos** en la flota, que permite separar la física del criterio con que se extrajeron las listas. Es la principal incertidumbre del trabajo.
2. **El origen de los 278 vehículos con evento y fecha por defecto** que salieron entre una versión de los datos y la otra, y el criterio de armado de la lista de vehículos con evento.
3. **Qué registra la fecha del evento:** hoy se corre 21 días porque cae unas dos semanas después del taller.
4. **Más eventos registrados** (hoy son 177), **la zona de uso** del vehículo (no la de venta) y **los costos reales** de una falla y de una inspección.
5. **Un piloto en sombra de tres meses en un país**, para medir prevalencia, falsas alarmas y detección reales.

Trabajo futuro. Reentrenar con los 557 vehículos y empaquetar el modelo. Validar toda mejora futura con datos nuevos, de una extracción posterior al 14-09-2026. Medir en el piloto lo que estos datos no permiten: si los avisos cambian hábitos, cuántas fallas se evitan y cuánto combustible se ahorra. Extender el circuito a otras fallas del sistema de postratamiento.

8. Conclusión

Se mostró que la telemetría que Ford ya recibe contiene información que anticipa la saturación del filtro de partículas, y que esa información es consistente con la física de la regeneración: los vehículos que fallan pasan más tiempo detenidos con el motor en marcha y con el motor por debajo de su temperatura de régimen, y la diferencia crece hacia el evento. Se mostró también que los datos contenían sesgos de muestreo y de formato capaces de producir métricas favorables sin ninguna capacidad predictiva, y que el PR-AUC por fila alcanza 0,177 con un puntaje que solo reconoce qué vehículo va a fallar, sin anticipar cuándo. Por eso el modelo se seleccionó con una métrica que exige anticipar: la detección por vehículo a presupuesto de falsas alarmas, comparada con un nulo que conserva el historial.

Con ese criterio, el modelo finalista, una GRU con atención de ~ 3.900 parámetros en un ensamble de tres semillas, detecta en vehículos no vistos $\sim 30\%$ de los eventos con 5% de falsas alarmas y $\sim 50\text{--}60\%$ con 20% , con una mediana de ~ 4.600 km (unos tres meses) de anticipación y un umbral que respeta su presupuesto fuera de muestra. Duplica la detección de los modelos tabulares y de supervivencia en el mismo conjunto. El circuito propuesto convierte cada alerta en un aviso verificable, con el punto de operación como decisión de Ford, a un costo estimado de USD 0,07–0,10 por vehículo y por año. Medir su impacto sobre las fallas evitadas y sobre la confianza del cliente requiere el piloto propuesto: primero en sombra y después con un grupo de control.

Referencias

- [1] Ford Motor Company (2026). *Ford Innovation Challenge III – AI Edition. Desafío: Data-Driven Powertrain Intelligence*. Documento del desafío y anexo de datos.
- [2] Guan, B., Zhan, R., Lin, H. y Huang, Z. (2015). Review of the state-of-the-art of exhaust

- particulate filter technology in internal combustion engines. *Journal of Environmental Management*, 154, 225–258.
- [3] van Noortwijk, J. M. (2009). A survey of the application of gamma processes in maintenance. *Reliability Engineering & System Safety*, 94(1), 2–21.
 - [4] Roberts, D. R. et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929.
 - [5] Saito, T. y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.
 - [6] Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
 - [7] Nosek, B. A., Ebersole, C. R., DeHaven, A. C. y Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606.
 - [8] Ke, G. et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems* 30.
 - [9] Craig, E., Zhong, C. y Tibshirani, R. (2021). Survival stacking: casting survival analysis as a classification problem. *arXiv:2107.13480*.
 - [10] Tutz, G. y Schmid, M. (2016). *Modeling Discrete Time-to-Event Data*. Springer.
 - [11] Cho, K. et al. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. En *Proceedings of EMNLP 2014*, 1724–1734.
 - [12] Bahdanau, D., Cho, K. y Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. En *ICLR 2015*.
 - [13] Dempster, A., Schmidt, D. F. y Webb, G. I. (2021). MiniRocket: A very fast (almost) deterministic transform for time series classification. En *Proceedings of KDD 2021*, 248–257.
 - [14] Das, A., Kong, W., Sen, R. y Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. En *ICML 2024*.
 - [15] Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of KDD 2019*, 2623–2631.
 - [16] Kingma, D. P. y Ba, J. (2015). Adam: A method for stochastic optimization. En *ICLR 2015*.
 - [17] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
 - [18] Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15.

A. Auditorías de fuga de información

Además de las defensas de construcción (gap de 500 km sobre la referencia corrida, partición por vehículo con los duplicados unificados, variables solo hacia atrás y corte en el fin de extracción común), todo candidato se somete a tres auditorías [18]. Sea $s_{i,c}$ el puntaje fuera de pliegue y $AP(\cdot)$ el PR-AUC por fila.

- **(a0) Nulo global.** Se permutan las variables entre todas las filas, se reentrena y se exige $AP \approx \bar{y} = 0,058$. Si no cae a la tasa base, hay información que no proviene de las variables.

- **(a') Contribución del instante.** Sin reentrenar, se reemplaza cada puntaje por el promedio de su vehículo, $\bar{s}_i = \frac{1}{n_i} \sum_c s_{i,c}$, y se reporta $AP(s) - AP(\bar{s})$: lo que el modelo sabía sobre *cuándo*, más allá de *qué vehículo*.
- **(b) Atajo de calendario.** Se agregan como variables las columnas de calendario (fechas de producción y de venta, temperatura ambiente) y se marca un atajo si el ROC sube más de 0,02.

Tabla 8: Auditorías en desarrollo [*dev*] (semilla 42 de la GRU; tasa base 0,058).

Modelo	(a0) PR-AUC	(a')	(b) Δ ROC	Resultado
GRU + viajes + estática (finalista)	0,061	+0,001	+0,004	aprueba
Survival stacking + motor y serie	0,056	+0,025	+0,009	aprueba

Ninguno de los dos presenta fuga: con las variables permutadas, el PR-AUC cae a la tasa base. La contribución (a') es positiva en ambos, y el puntaje del finalista crece a medida que se acerca el evento (Figura 6). Ninguno muestra el atajo de calendario.

B. Resultados de todos los modelos

Cada modelo se entrenó con todo el conjunto de desarrollo (semilla 42, salvo la GRU, que es el ensamble de tres semillas) y se evaluó con la misma métrica en los 103 vehículos de prueba. Estas evaluaciones se hicieron después de la evaluación del finalista y son descriptivas: no se usaron para elegir.

Tabla 9: Detección $D(\alpha)$ (%) en el conjunto de prueba según el presupuesto de falsas alarmas [*test*]. “Prim.” es $\bar{D}$, ec. (8).

Modelo	2%	5%	10%	15%	20%	25%	30%	Prim.	AUC auto	dev (5 · 10 · 20%)
GRU ×3 (finalista)	15,6	31,2	46,9	62,5	62,5	65,6	68,8	50,8	0,794	27 · 42 · 61
Survival stacking	3,1	18,8	21,9	21,9	43,8	53,1	53,1	26,6	0,710	14 · 24 · 42
LightGBM (53 features)	0,0	15,6	25,0	28,1	34,4	53,1	56,2	25,8	0,725	18 · 28 · 42
Logística L2 (53 features)	0,0	6,2	12,5	31,2	34,4	46,9	53,1	21,1	0,679	15 · 23 · 37
SS + efecto aleatorio (GPBoost)	3,1	9,4	9,4	9,4	12,5	12,5	12,5	10,2	0,363	6 · 9 · 17
Azar, media / p95 (nulo de la GRU)	3,4 / 9,4	7,0 / 15,6	13,7 / 25,0	18,6 / 31,2	24,4 / 40,6	28,6 / 43,8	33,9 / 50,0	—	—	—

Tabla 10: Con el umbral fijado en desarrollo [*test*]: detección y tasa de falsas alarmas realizada en prueba.

Modelo	Detección (%) al 5 · 10 · 20 %	Falsas alarmas reales (%)
GRU ×3 (finalista)	20 · 34 · 57	5,8 · 8,9 · 18,2
Survival stacking	13 · 20 · 33	4,6 · 8,3 · 15,6
LightGBM (53 features)	16 · 25 · 36	7,5 · 10,7 · 16,9
Logística L2 (53 features)	12 · 16 · 33	8,8 · 11,8 · 18,3
SS + efecto aleatorio (GPBoost)	8 · 11 · 14	6,5 · 11,3 · 21,5

Comparación pareada en prueba (bootstrap por vehículo, diferencia de $\bar{D}$ en puntos, IC 95 %): GRU – survival stacking, +24,2 [0,8; 43,0].

Tabla 11: Modelos principales en desarrollo [*dev*]: $D(\alpha)$ (%), promedio de 3 repeticiones de la validación cruzada.

Modelo	AUC por vehículo	$\alpha = 5\%$	10 %	20 %
GRU + viajes + estática, $\times 3$ (finalista)	0,82	27	42	61
Survival stacking	0,72	14	24	42
LightGBM (53 variables)	0,72	18	28	42
Logística L2	0,71	15	23	37
Nulo (historial conservado)	–	5	11	21

C. Diccionario de variables

Las 53 variables agregadas se calculan sobre la ventana $(c - W, c]$ según la ec. (10), como `agregador(variable derivada)`. Las variables con prefijo `aux_` se conservan para auditoría y no entran en ningún modelo. Agregadores: `per_1000km`, conteo por 1.000 km; `per_day`, por día; `half_*`, segunda mitad de la ventana menos la primera; `gap_*`, distancia entre eventos; `any`, ocurrencia.

A · Térmica y trayectos cortos

```
idle_frac: mean(idle)
idle_per_1000km: per_1000km(idle)
idle_frac_trend: half_mean_delta(idle)
short_trip_frac_5km: mean(short_trip_moving)
trips_below_regime_temp_frac: mean(below_regime)
below_regime_moving_frac: mean(below_regime_moving)
below_regime_frac_trend: half_mean_delta(below_regime)
engine_temp_avg_median: median(EngineTemperatureAvg_moving)
engine_temp_max_median: median(EngineTemperatureMax_moving)
engine_temp_amplitude_mean: mean(engine_temp_amplitude_moving)
coolant_temp_end_mean: mean(CoolantTemperatureEnd_moving)
coolant_temp_start_median: median(CoolantTemperatureStart)
cold_start_frac: mean(cold_start)
chained_trip_frac: mean(chained)
trip_distance_median_km: median(trip_km_moving)
trip_distance_p25_km: p25(trip_km_moving)
trip_duration_median_min: median(trip_duration_min_moving)
```

B · Regeneración (DPF)

```
regenerations_per_1000km: per_1000km(regen_drop)
regenerations_trend_per_1000km: half_count_delta_per_1000km(regen_drop)
distance_between_regen_mean_km: gap_mean_km(regen_drop)
distance_between_regen_trend: gap_trend_km(regen_drop)
km_since_last_regen: km_since_last(regen_drop)
regen_residual_mean: mean(regen_residual)
regen_start_level_mean: mean(regen_start_level)
dpf_end_mean: mean(AirRegenerationEnd)
dpf_end_max: max(AirRegenerationEnd)
dpf_end_slope_per_1000km: half_slope_per_1000km(AirRegenerationEnd)
```

```
dpf_positive_delta_frac: mean(dpf_positive_delta_moving)
dpf_saturated_frac: mean(dpf_saturated_end)
filter_abnormal_end_frac: mean(filter_abnormal_end)
filter_cleaning_auto_end_frac: mean(filter_cleaning_auto_end)
manual_regen_ever: any(filter_manual)
```

C · Uso

```
speed_kmh_mean: mean(speed_kmh_moving)
trips_below_30kmh_frac: mean(urban_moving)
moving_trips_per_1000km: per_1000km(moving)
km_per_day: per_day(trip_km)
trips_per_day: per_day(moving)
hours_between_trips_median: median(soak_min)
aux_air_temp_avg: mean(AirTemperatureAvg)
aux_air_temp_min: mean(AirTemperatureMin)
```

D · Severidad (mensajes, aceite, consumo)

```
msg_full_per_1000km: per_1000km(msg_full)
msg_overloaded_per_1000km: per_1000km(msg_overloaded)
msg_overloaded_ever: any(msg_overloaded)
msg_over_limit_per_1000km: per_1000km(msg_over_limit)
msg_over_limit_ever: any(msg_over_limit)
msg_at_limit_ever: any(msg_at_limit)
msg_cleaning_auto_per_1000km: per_1000km(msg_cleaning_auto)
msg_cleaning_auto_trend_per_1000km: half_count_delta_per_1000km(msg_cleaning_auto)
msg_abnormal_frac: mean(msg_abnormal)
msgs_per_1000km: per_1000km(msg_any)
oil_life_mean: mean(oil_life)
oil_life_slope_per_1000km: half_slope_per_1000km(oil_life)
fuel_pct_per_100km_median: median(fuel_pct_per_100km)
aux_regen_marker_per_1000km: per_1000km(regen_marker)
Control de ventana
n_trips_window: count(*)
window_km_covered: rango(OdometerTripEnd)
```

Canales de la representación secuencial (11). La ventana se divide en 20 tramos de 50 km; “zero” rellena con cero un tramo sin datos y “carry” arrastra el último valor dentro de la ventana. Se agregan país, motor y serie en codificación *one-hot*.

Canal	Fuente	Columna	Por tramo	Relleno
n_records	signals	*	count	zero · log1p
observed	signals	*	any	zero
acum_mean	signals	Acumulation	mean	carry
acum_max	signals	Acumulation	max	carry
acum_rise	signals	acum_rise	sum	zero
regen_drops	signals	acum_regen_drop	sum	zero
msg_full_frac	signals	msg_full	mean	zero
msg_severe_frac	signals	msg_severe	mean	zero
msg_cleaning_auto_frac	signals	msg_cleaning_auto	mean	zero
n_trips	trips	*	count	zero · log1p
idle_frac	trips	idle	mean	carry
below_regime_frac	trips	below_regime_moving	mean	carry
speed_kmh	trips	speed_kmh_moving	mean	carry
trip_km	trips	trip_km_moving	mean	carry
trip_duration_min	trips	trip_duration_min_moving	mean	carry