



Ford Innovation Challenge III – AI Edition

Predicción temprana de la degradación del filtro de partículas
a partir de la telemetría de vehículos conectados

Área: Data-Driven Powertrain Intelligence

Equipo SOG

Santino Cardelli · Gonzalo Malaspina · Octavio Romagnoli

Octubre 2026

Resumen

En este trabajo se desarrolló y se validó un método para anticipar la saturación del filtro de partículas diésel (DPF) a partir de la telemetría que los vehículos conectados de Ford ya transmiten: resúmenes de viaje y mensajes del sistema de postratamiento. El problema se formuló como un panel de cortes cada $\Delta = 500$ km, donde en cada corte un modelo observa los últimos $W = 1.000$ km y estima la probabilidad de que el evento ocurra entre $G = 500$ y $G + H = 3.500$ km más adelante, sin acceso a los 500 km inmediatamente previos. Antes de modelar se identificaron y corrigieron sesgos de muestreo y de formato que inflaban cualquier métrica: dos cohortes muestreadas en períodos de producción distintos, una fecha de evento posterior a la intervención en taller y un contador de regeneraciones que deja de reportar. Se mostró además que el PR-AUC por fila de este panel tiene un piso de 0,177 que se alcanza sin información temporal (*techo de cohorte*), por lo que la selección de modelos se hizo con la detección por vehículo a un presupuesto fijo de falsas alarmas, contrastada con un nulo de permutación que conserva el largo de cada historial. Sobre más de 40 configuraciones (modelos lineales, *gradient boosting*, supervivencia en tiempo discreto y redes recurrentes), el modelo finalista es una red GRU con atención de ~ 3.900 parámetros sobre una secuencia de 20 tramos de $50 \text{ km} \times 15$ canales, más país, motor y serie, combinada en un ensamble por rango de tres semillas. En un conjunto de prueba de 111 vehículos separado antes de cualquier análisis (103 con datos, 32 con evento), detecta $\sim 30\%$ de los eventos con 5% de vehículos sanos con falsa alarma (el nulo da 7%), $\sim 40\text{--}50\%$ con 10% y $\sim 50\text{--}60\%$ con 20% , con una mediana de ~ 4.600 km (unos tres meses) entre la primera alerta y el evento. Con el umbral fijado en desarrollo, las falsas alarmas realizadas en prueba fueron 5,8, 8,9 y 18,2%. El costo de operación estimado es de USD 0,07–0,10 por vehículo y por año, sin sensores adicionales.

Índice

Resumen	1
1. Descripción general del desafío	2
2. Contexto del proceso	3
3. Definición del desafío	3
4. Datos técnicos relevantes	5
5. Expectativas de solución	9
6. Información complementaria	15
7. Conclusión	16
Referencias	16
A. Auditorías de fuga de información y techo de cohorte	17
B. Resultados de todos los modelos	18
C. Diccionario de variables	19

1. Descripción general del desafío

El desafío pide una metodología basada en inteligencia artificial para predecir eventos de degradación de la eficiencia de combustión y del ingreso de oxígeno al motor a partir de datos de vehículos conectados [1]. En un motor diésel, el componente que se degrada por el uso y que afecta a la vez la combustión y el flujo de gases es el filtro de partículas (DPF): una restricción del escape aumenta la contrapresión, empeora el llenado de los cilindros y obliga a la unidad de control a modificar la estrategia de inyección [2].

1.1. Física del filtro de partículas

El DPF retiene el hollín del escape en las paredes de un monolito cerámico. La masa de hollín acumulada m_s evoluciona según un balance entre lo que ingresa y lo que se oxida,

$$\frac{dm_s}{dt} = \dot{m}_{\text{in}} - k(T) m_s, \quad k(T) = A \exp\left(-\frac{E_a}{RT}\right), \quad (1)$$

donde $\dot{m}_{\text{in}}$ es el caudal de hollín emitido por el motor, T la temperatura del filtro y $k(T)$ una constante de oxidación de tipo Arrhenius [2]. Por la dependencia exponencial con T , la oxidación solo es apreciable por encima de umbrales de temperatura: la regeneración pasiva con NO_2 opera aproximadamente entre 250 y 450 °C, y la activa con O_2 requiere más de ~ 550 °C, que la unidad de control fuerza con postinyección cuando la carga estimada supera un umbral [2]. Una regeneración activa necesita, por lo tanto, varios minutos de motor caliente con carga sostenida. En un uso con viajes cortos, ralenti prolongado o motor por debajo de su temperatura de régimen, la regeneración comienza y se interrumpe; el segundo término de la ecuación (1) queda chico frente al primero, la carga crece y el vehículo termina en un modo de protección y en el taller.

De la ecuación (1) se desprenden dos consecuencias que orientaron el trabajo. Primero, el estado del filtro es *reversible*: la carga de hollín se reduce con cada regeneración completa, a diferencia de la ceniza, que se acumula de forma irreversible pero en escalas de más de 10^5 km [2]. Segundo, el riesgo depende de la *historia de uso reciente* (temperaturas alcanzadas, duración de los viajes, tiempo detenido) más que del kilometraje acumulado.

1.2. Lo que se encontró en los datos

El evento es del filtro, con otra denominación. La tabla de viajes no trae las columnas del DPF que documenta el anexo de datos, pero sí `AirRegenerationStart/End` y `AirFilterStart/End`, que el anexo no menciona. Son el valor, al inicio y al final de cada viaje, del nivel de acumulación del filtro (escala 0–100) y de los nueve niveles de mensaje del sistema que reporta la tabla de señales: coinciden con ella en el 99,8 y el 99,97 % de los pares viaje–señal. Como el significado no fue confirmado por Ford, en este informe se habla de *nivel de acumulación del filtro*.

Es saturación por uso, no desgaste. El evento ocurre con una mediana de ~ 12.800 km, dos órdenes de magnitud antes de la escala de la ceniza. Se buscó una variable de daño monótona e irreversible, que es la premisa de los modelos de degradación por procesos gamma [3], y no se encontró ninguna. Esto descartó ese enfoque y orientó el modelado hacia los hábitos de manejo y el estado reciente del filtro, en línea con la ecuación (1).

No todo “uso indebido” se sostiene. Comparando contra vehículos sanos *del mismo mercado*, lo que crece hacia el evento es el tiempo detenido con el motor en marcha y la fracción de viajes que no alcanzan la temperatura de régimen. La velocidad media y la fracción de viajes cortos no separan dentro del mercado: con la primera entrega de datos, la velocidad parecía la mejor variable y medía en realidad la diferencia entre dos países.

Lo que se propone. Un modelo secuencial que lee los últimos 1.000 km del vehículo y un circuito que convierte cada alerta en una acción. Al conductor no se le habla de fallas: se le comunican hábitos modificables, comparados con vehículos sanos de su zona.

2. Contexto del proceso

La telemetría llega a la nube de forma continua, pero la degradación se identifica una vez manifestada: en un servicio programado o cuando el cliente la reporta [1]. El desafío se ubica, por lo tanto, en la posventa, y el valor de una predicción depende de cuánto antes de esa identificación llega.

El proceso reactivo queda registrado en la telemetría. La fecha registrada del evento es posterior a la intervención en el taller. En la primera entrega de datos coincidía con ella: los cambios de aceite se concentraban en ± 3 días. En la segunda entrega, la fecha de los mismos vehículos cae una mediana de 14 días más tarde, y en las dos semanas previas ya aparecen el cambio de aceite y el ralentí prolongado característico de una regeneración forzada en servicio (1,5 a 1,8 veces la tasa de base). Después del evento, además, el uso cambia: la fracción de viajes por debajo de la temperatura de régimen baja en el 72 % de los vehículos.

Ambos hechos tienen consecuencias directas sobre la formulación. Si el modelo observara los días del taller, haría la detección reactiva que Ford ya tiene. Por eso: (i) la referencia del evento es la fecha registrada menos 21 días; (ii) el modelo nunca observa los 500 km previos a esa referencia (§3.1); y (iii) ningún dato posterior al evento entra en ninguna ventana.

Dónde entra la predicción. En la posventa, la alerta alimenta un circuito que termina en una acción (Figura 1). Si en la ventana del vehículo hay un hábito modificable que lo distingue de los sanos de su mercado, se envía un consejo al conductor; si no lo hay, se agenda un contacto del concesionario; si el riesgo se mantiene alto dos revisiones después, el caso escala. La decisión es determinista y la define Ford; la redacción la hacen agentes de lenguaje cuyo texto valida un verificador programado (§5.2.1).




Figura 1: Circuito de posventa propuesto. El modelo decide si hay alerta, la política (recuadro punteado) decide la acción y los agentes solo redactan.

3. Definición del desafío

Ford pide anticipar *el momento* en que un vehículo se aproxima a la degradación, con margen para actuar antes de que el cliente lo perciba [1]. Son dos exigencias que tiran en direcciones opuestas: *anticipar* obliga a no mirar los últimos kilómetros, que es donde la señal es más fuerte, y *el momento* exige información sobre *cuándo*, no solo sobre *qué vehículo*. Esta sección traduce ambas exigencias a un problema de aprendizaje supervisado y a una métrica que no se pueda satisfacer con atajos.

3.1. Formulación: panel de cortes con gap de blanking

Sea i un vehículo con historial observado hasta el odómetro L_i y, si tiene evento, E_i el odómetro en la referencia del evento (fecha registrada $- 21$ d, traducida a km con el anclaje del calendario). Se definen cortes sobre una grilla de paso Δ ,

$$c \in \{k\Delta : k \in \mathbb{N}\}, \quad c \leq \begin{cases} E_i - G & \text{si } i \text{ tiene evento,} \\ L_i - G - H & \text{si } i \text{ es sano,} \end{cases} \quad (2)$$

y para cada par (i, c) la etiqueta

$$y_{i,c} = \mathbb{K}\{G \leq E_i - c \leq G + H\}, \quad (3)$$

con $y_{i,c} = 0$ para los sanos. La condición sobre los sanos en (2) exige que el vehículo haya sido observado hasta $c + G + H$: un corte sin ese seguimiento no es un negativo verificable y se descarta (censura). La entrada del modelo es una función de los datos con odómetro en la ventana $(c - W, c]$, de modo que entre la última observación y el comienzo del horizonte siempre hay al menos G km sin información (Figura 2). Se usan

$$W = 1.000 \text{ km}, \quad G = 500 \text{ km}, \quad H = 3.000 \text{ km}, \quad \Delta = 500 \text{ km}. \quad (4)$$

Se descartan además las ventanas con menos de 5 viajes o que cubren menos de $W/2$ en km recorridos.




Figura 2: Ventana de entrada W , gap de blanking G y horizonte H alrededor de un corte c .

Elección de los parámetros. El gap G es la condición de anticipación: sin él, el modelo aprende los mensajes de “filtro sobrecargado” de los últimos kilómetros, que son la definición del evento y no un precursor. Ventanas de 2.000 y 3.000 km dieron resultados equivalentes a $W = 1.000$ km y reducen la cantidad de eventos con cortes válidos. El horizonte H ubica los positivos donde el perfil alineado al evento muestra señal (§4.5).

Eje temporal. El evento se ordena mejor por edad del vehículo que por odómetro: el desvío estándar del logaritmo del instante del evento es 0,38 en días desde la venta y 0,91 en km. Los cortes se definen en km, porque es el eje en que se acumula el uso, y la anticipación se reporta en km y en días.

Emparejamiento de los sanos. Los cortes de los vehículos sanos se muestrean con la misma distribución conjunta de odómetro (celdas de 4.000 km) y mes calendario que los cortes positivos. Sin el emparejamiento por mes, tres variables de calendario elevaban el ROC de 0,67 a 0,76; con él, de 0,57 a 0,60: el calendario dejaba de ser un atajo.

El panel de desarrollo resultante tiene 11.703 filas de 426 vehículos con cortes válidos (135 con evento) y 682 filas positivas, una tasa de 0,058.

Restricciones de validación. (i) Partición agrupada por vehículo [4]: un vehículo nunca aparece en entrenamiento y validación a la vez; los pliegues se estratifican por etiqueta, mercado y motor, y la validación cruzada de 5 pliegues se repite 3 veces. (ii) Un conjunto de prueba congelado antes de examinar cualquier variable contra la etiqueta. (iii) Variables calculadas solo hacia atrás del corte, con imputación y escalado ajustados en el entrenamiento de cada pliegue. (iv) Auditorías de fuga de información obligatorias para todo candidato (Anexo A).

3.2. Métrica de evaluación

El techo de cohorte. Todas las filas positivas del panel pertenecen a vehículos con evento. Un puntaje que solo indica la cohorte, $s_{i,c} = \mathbb{K}\{i \text{ tiene evento}\}$, sin ninguna información sobre el instante, obtiene

$$\text{PR-AUC}_{\text{cohorte}} = 0,177, \quad \text{lift} = \frac{0,177}{0,058} = 3,03, \quad (5)$$

(0,263 y 2,10 con la primera entrega). La meta inicial de lift, de 1,6 a 2, se alcanzaba entonces sin anticipar nada, y ningún modelo superó ese techo. El PR-AUC por fila [5] de este panel mide

sobre todo *qué vehículo* y no se usó para elegir; se reporta en el Anexo A. Por la misma razón no se reporta exactitud: con 5,8 % de positivos, la predicción constante “sin evento” da 94 %.

Detección por vehículo a presupuesto de falsas alarmas. Sea $s_{i,c}$ el puntaje del corte c y $c_1 < c_2 < \dots$ los cortes de i . Un vehículo queda *alertado* con umbral τ cuando su puntaje supera τ en dos cortes consecutivos, lo que equivale a

$$m_i = \max_t \min(s_{i,c_t}, s_{i,c_{t+1}}) \geq \tau. \quad (6)$$

La condición de dos cortes evita que un pico aislado cuente como alerta. Si $\mathcal{S}$ y $\mathcal{F}$ son los conjuntos de vehículos sanos y con evento, para cada presupuesto α de falsas alarmas se toma el menor umbral que lo cumple y se mide la fracción de eventos detectados:

$$\tau_\alpha = \min \left\{ \tau : \frac{1}{|\mathcal{S}|} \sum_{j \in \mathcal{S}} \mathbb{1}\{m_j \geq \tau\} \leq \alpha \right\}, \quad D(\alpha) = \frac{1}{|\mathcal{F}|} \sum_{i \in \mathcal{F}} \mathbb{1}\{m_i \geq \tau_\alpha\}. \quad (7)$$

Por construcción (2), toda alerta en un vehículo con evento ocurre al menos G km antes de E_i . El criterio primario es la detección media en cuatro presupuestos,

$$\bar{D} = \frac{1}{4} [D(0,05) + D(0,10) + D(0,15) + D(0,20)], \quad (8)$$

que pondera el rango de operación plausible para una flota.

Nulo con el historial conservado. m_i es el máximo sobre los cortes del vehículo, de modo que un historial más largo tiene más oportunidades de superar τ . Con la primera entrega, los vehículos con evento tenían en promedio 18,25 cortes y los sanos 9,00, y el largo del historial como único puntaje daba lift 1,79. Por eso $D(\alpha)$ se compara con su distribución bajo la hipótesis nula, que se obtiene permutando los puntajes entre todas las filas y conservando la cantidad de cortes de cada vehículo (1.000 permutaciones). Con las bolsas asimétricas de la primera entrega, ese nulo “detectaba” 10 % al 5 % de falsas alarmas.

Comparaciones. La diferencia entre dos modelos A y B se estima con un bootstrap pareado por vehículo [6]: se remuestrean vehículos con reposición, se recalcula $\bar{D}_A - \bar{D}_B$ sobre los mismos vehículos y se reporta el intervalo percentil del 95 % (1.000 réplicas). El umbral también se fija *fuera de muestra* (con los sanos de desarrollo) para medir la tasa de falsas alarmas realizada en prueba. Con unos 12 eventos por pliegue, cada candidato nuevo agrega una comparación múltiple; por eso los candidatos decisivos y sus criterios de aceptación se fijaron por escrito antes de medirlos [7].

3.3. Impacto operativo

El desafío menciona la satisfacción del cliente, los costos de garantía, la vida útil percibida y la planificación de los concesionarios [1]. El sistema propuesto actúa sobre ellos a través de tres palancas: el aviso llega con unos tres meses de margen (§5.1.4), en lenguaje del cliente y con una acción concreta; los casos llegan priorizados al concesionario; y el presupuesto α de la ecuación (7) es un parámetro que Ford elige según su capacidad de atención. La cantidad de fallas evitadas no es medible con estos datos y es la métrica central del piloto propuesto (§5.2.1).

4. Datos técnicos relevantes

4.1. Fuentes, esquema y restricciones

Se recibieron las tres tablas del anexo de datos [1] (estática del vehículo, resúmenes de viaje *TripSummary* y señales *DynamicInformation*), cada una dividida en dos cohortes (vehículos con y sin evento) y en dos entregas. La segunda entrega trajo una tabla estática nueva, con ciudad de venta y país, y nuevos viajes y señales de los vehículos con evento; los de los sanos son idénticos byte a byte a los de la primera. En total son $\sim 2,5 \times 10^6$ viajes y $\sim 10^7$ señales.

Contraste con el diccionario. *TripSummary* trae 25 de las 40 columnas documentadas: faltan posición GPS, elevación, presión de neumáticos, hollín de regeneración manual y autonomía. Las columnas del DPF llegan con otra denominación (§1). No hay VIN: la clave es un código anonimizado, y la unión de las tres tablas es completa. El evento no está marcado fila a fila: la fecha del evento existe en el 100 % de los vehículos de la cohorte con evento y en ninguno de la otra. *La cohorte es la etiqueta*, y por lo tanto nunca se usa como variable. El historial alcanza holgadamente para ventanas de varios miles de km (mediana de ~ 2.000 viajes y más de un año por vehículo).

4.2. Calidad de datos: sesgos, limpieza, faltantes y atípicos

Los problemas de la Tabla 1 tienen algo en común: ninguno produce un error de ejecución, y todos producen una métrica mejor de lo que corresponde. Cada corrección se aplica al leer los archivos, se declara en un archivo de configuración y tiene un test automático.

La imputación (mediana) y el escalado se ajustan en el entrenamiento de cada pliegue. Queda una pregunta que solo Ford puede responder: entre las dos entregas salieron 278 vehículos con evento y fecha por defecto, concentrados por mercado; no se sabe si son eventos sin fecha o un error de extracción, y eso explica en parte la variación de la tasa entre países.

4.3. Universo de estudio y partición




Figura 3: Del conjunto recibido al conjunto de prueba. La partición se sorteó una sola vez (semilla 42, estratificada por evento, mercado y motor) antes de examinar ninguna variable contra la etiqueta.

Se conserva el período de producción en que se muestrearon ambas cohortes: un vehículo sano producido en octubre de 2025 no es un negativo verificable si de esa época no se registró ningún evento. Se evaluó también la alternativa de incluir los 434 vehículos excluidos: con ellos, los modelos ordenaban *peor* a los vehículos comparables, porque aprendían la fecha de producción. Con la segunda entrega la partición se volvió a sortear; 36 de los 111 vehículos de prueba habían estado en el conjunto de desarrollo de la primera, y los resultados de prueba se reportan también sin ellos (§5.1.3).

La segunda entrega modificó varias conclusiones: la velocidad dejó de separar dentro del mercado; apareció una trayectoria hacia el evento que antes no se observaba; la ventana de calendario del registro de eventos resultó ser propia de la extracción anterior; y el motor ENG_3, sin eventos en la primera entrega, pasó a tener 47 (46 en Brasil).

4.4. Ingeniería de variables

Variables derivadas por viaje. Sobre cada viaje j con distancia d_j y duración δ_j se calcula, entre otras, la velocidad $v_j = d_j/\delta_j$ (con tope de 200 km/h), el indicador de ralentí $\mathbb{K}\{d_j = 0\}$, el de motor bajo régimen $\mathbb{K}\{T_{\text{máx},j}^{\text{motor}} < 70\text{ °C}\}$ entre los viajes con desplazamiento, y el arranque en frío. Las fracciones “de viaje” se calculan solo entre los viajes con $d_j > 0$. Como el contador de regeneraciones deja de reportar, una regeneración se define a partir del nivel de acumulación

Tabla 1: Problemas encontrados en los datos, evidencia y tratamiento.

Problema	Evidencia	Tratamiento
<i>Muestreo y etiqueta</i>		
Cohortes muestreadas en períodos de producción distintos	Antes del 20-01-2025 solo hay vehículos con evento (93) y después de julio de 2025 solo sanos (341, con ~ 50 eventos esperados). Con ellos, la fecha de producción sola separa las cohortes con AUC 0,87 dentro del mercado	Universo restringido al período común (§4.3)
Fecha registrada posterior al taller	Cambio de aceite y ralentí prolongado en las dos semanas previas	Referencia del evento = fecha – 21 d
Tasa de eventos por país dependiente de la extracción	De 0 % (PER) a 48 % (COL), en orden inverso a la cantidad de vehículos con evento sin fecha excluidos por mercado	Toda comparación entre cohortes, dentro del mercado
13 vehículos con dos códigos	Mismos viajes bajo dos identificadores (Jaccard 1,0 sobre fecha y odómetro)	Se unifican antes de particionar
Formato de la segunda entrega	Columna del evento renombrada; fecha de producción con otro origen (+538 d); una fila por evento; filas repetidas; extracción de la cohorte con evento diez días más larga (16.911 viajes)	Corrección al leer y corte en el fin de extracción común (14-09-2026)
Cambio de uso posterior al evento	Viajes bajo régimen: bajan en el 72 % de los vehículos; velocidad: sube en el 79 %	Ningún dato posterior al evento entra en una ventana
<i>Columnas, faltantes y atípicos</i>		
Contador de regeneraciones interrumpido	Cero registros desde el 25-05-2026 en toda la flota; su correlación con la etiqueta (0,317) era calendario	Solo para auditoría; regeneración = caída de la acumulación, ec. (9)
Velocidad imposible o nula	Hasta $1,36 \times 10^5$ km/h; nula <i>exactamente</i> en los viajes de 0 km (33 % de las filas)	Recalculada como km/duración con tope de 200 km/h; el ralentí es una variable, no un faltante
Temperaturas, duraciones y km extremos	-73°C , viajes de 20 días y de -230 km ($< 0,05$ % cada uno)	Topes físicos fijos; viajes con km negativos o sin odómetro, descartados
Columnas con otra semántica	Combustible > 100 en el 10,5 % de los viajes; vida del aceite constante dentro del viaje; acumulación hasta 100	Combustible como índice relativo; pendiente del aceite en la ventana; saturación = nivel ≥ 95
Fechas en dos formatos	Sin declararlo, el parser anulaba 4.464 inicios de viaje y 18.124 señales	Formato ISO 8601 explícito
Odómetro de señales nulo	11 % en la primera entrega (9 vehículos); 0,5 % en la segunda	La ventana se ubica con el odómetro de los viajes
Tramos sin viajes	Huecos de 50 km en la secuencia	Canal de cobertura y arrastre del último valor

a:

$$r_j = \mathbb{K}\{a_j^{\text{inicio}} - a_j^{\text{fin}} > 15\}, \quad (9)$$

es decir, una caída de más de 15 puntos entre el inicio y el final del viaje. Con un umbral de 5 puntos, el saldo acumulado de subidas y caídas no seguía la acumulación (correlación 0,005 contra 0,45): el umbral bajo contaba ruido.

Representación agregada. Para los modelos tabulares y de supervivencia, la ventana se resume en 53 variables

$$x_{i,c}^{(f)} = \text{agg}_f(\{z_j^{(f)} : j \in i, \text{odo}_j \in (c - W, c]\}), \quad (10)$$

donde $z^{(f)}$ es una variable derivada y agg_f un agregador: media, mediana, percentil, conteo por 1.000 km o por día, distancia media entre eventos, km desde el último evento, y tendencia como

diferencia entre la segunda y la primera mitad de la ventana. Se agrupan en cuatro familias: térmica y trayectos cortos (17), regeneración (15), uso (6) y severidad de mensajes (13), más dos de control de cobertura (Anexo C).

Representación secuencial. Para los modelos recurrentes, la ventana se divide en $T = 20$ tramos de 50 km y en cada tramo t se calculan $C = 15$ canales, lo que da un tensor

$$\mathbf{X}_{i,c} \in \mathbb{R}^{T \times C}, \quad \mathbf{X}_{i,c}[t,k] = \text{agg}_k(\{z_j^{(k)} : \text{odo}_j \in (c - W + 50(t-1), c - W + 50t]\}). \quad (11)$$

Seis canales describen cómo se viaja (cantidad de viajes, ralentí, bajo régimen, velocidad, km y duración por viaje) y nueve el estado del filtro (acumulación media y máxima, subida de la acumulación, regeneraciones, tres fracciones de mensajes, registros y cobertura). Un tramo sin datos se rellena con cero en los conteos y con el último valor de la ventana en los niveles; el canal de cobertura indica al modelo cuál es cuál. Se agregan país, motor y serie como variables estáticas.

Variables excluidas del modelo. Se conservan solo para auditoría las que miden calendario o cohorte y no el vehículo: fechas de producción y de venta, temperatura ambiente (los vehículos con evento circulan en zonas más frías que los sanos de su mercado) y el contador de regeneraciones interrumpido.

4.5. Análisis exploratorio

Todo el análisis se hizo sobre el conjunto de desarrollo y compara contra sanos *del mismo mercado*: con cinco mercados de tasas muy distintas, una comparación agrupada confunde país con vehículo. Para una variable x y una distancia al evento d , se estima

$$\theta(d) = P(x_{\mathcal{F}} > x_{\mathcal{S}} \mid \text{mismo mercado y tramo de odómetro}, E - c \in d), \quad (12)$$

la probabilidad de que un corte de un vehículo con evento supere a uno sano comparable ($\theta = 0,5$: sin separación).




Figura 4: Probabilidad $\theta(d)$ de la ecuación (12) para cuatro variables, según la distancia al evento.

La Figura 4 muestra que la huella crece hacia el evento: la fracción de ralentí pasa de $\theta = 0,60$ a $0,64$ y $0,76$, y la de viajes bajo régimen de $0,55$ a $0,62$ y $0,73$, mientras la temperatura del refrigerante al final del viaje baja (θ de $0,47$ a $0,29$) y la velocidad no se aparta de $0,5$. Lo que crece es el tiempo detenido con el motor en marcha y la imposibilidad de alcanzar temperatura, consistente con la ecuación (1); lejos del evento la señal es débil. La señal también aparece temprano: con los primeros 60 días de uso tras la venta, el ralentí ordena vehículos con AUC

0,636 dentro del mercado, que es información de *qué vehículo*. Por último, el riesgo es función de la edad y no del odómetro: la tasa de eventos crece hasta los ~ 4 meses desde la venta y luego se estabiliza en 3 a 4 eventos cada 100 vehículos-mes, sin efecto del mes calendario ($p = 0,16$).

5. Expectativas de solución

La solución combina los cuatro campos que menciona el desafío [1]: análisis de datos (§4), aprendizaje automático (modelos lineales, *gradient boosting* y supervivencia en tiempo discreto con validación agrupada), aprendizaje profundo (el modelo finalista es una red recurrente con atención) e IA generativa (agentes que redactan los avisos bajo un verificador programado).

5.1. Objetivo de mejora: anticipar con el mayor margen posible

5.1.1. Modelos evaluados

Todos los candidatos se entrenaron sobre el mismo panel, con los mismos pliegues, y se evaluaron con la métrica (8). Las familias principales fueron:

- **Modelos tabulares** sobre las 53 variables agregadas (10): regresión logística con regularización L2 y L1, y LightGBM [8].
- **Supervivencia en tiempo discreto** (*survival stacking* [9, 10]): cada fila se replica en B tramos de km del horizonte y un clasificador estima el riesgo condicional por tramo,

$$h_b(\mathbf{x}) = P(E - c \in I_b \mid E - c > I_{b-1}, \mathbf{x}), \quad s(\mathbf{x}) = 1 - \prod_{b=1}^B (1 - h_b(\mathbf{x})), \quad (13)$$

donde s es la probabilidad de evento dentro del horizonte. Usa la información de los cortes censurados que la clasificación binaria descarta.

- **Modelos secuenciales** sobre el tensor (11): CNN-LSTM [11], GRU con atención [12, 13] y MiniRocket [14].
- **Alternativas descartadas con evidencia:** proceso gamma de degradación [3] (no hay variable de daño irreversible), horizonte ordinal, pronóstico de series con TimesFM [15] sin ajuste, modelo de cura por hito posventa, efecto aleatorio por vehículo y varios ensambles.

Con la primera entrega (290 vehículos de desarrollo y dos mercados), los modelos tabulares aprendían *qué vehículo* y no *cuándo*, lo que motivó el cambio de métrica de la §3.2. Con la segunda entrega (446 vehículos y el triple de eventos), los modelos secuenciales pasaron adelante (Tabla 2).

5.1.2. Arquitectura del modelo finalista

El finalista es una red GRU unidireccional con atención y una rama estática de fusión tardía (Figura 5). Para cada corte, la red recibe la secuencia $\mathbf{x}_1, \dots, \mathbf{x}_T \in \mathbb{R}^C$ (las filas de $\mathbf{X}_{i,c}$, estandarizadas con el entrenamiento del pliegue) y actualiza un estado oculto $\mathbf{h}_t \in \mathbb{R}^d$, $d = 24$, mediante las compuertas de actualización $\mathbf{z}_t$ y de reinicio $\mathbf{r}_t$ [12]:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z), \quad (14)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r), \quad (15)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h), \quad (16)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (17)$$

La compuerta $\mathbf{z}_t$ decide qué parte del estado se reemplaza con la información del tramo y $\mathbf{r}_t$ cuánto del pasado se usa para calcularla. Esto permite representar tendencias que un agregado (10) pierde, como una acumulación que sube de forma sostenida o viajes que se acortan. La

Tabla 2: Resultados que determinaron el finalista, en desarrollo [*dev*]. $D(\alpha)$ en % al 5, 10 y 20 % de falsas alarmas; diferencias en puntos de $\bar{D}$ con IC del 95 % por bootstrap pareado.

Comparación	Resultado	Lectura
42 configuraciones, misma métrica	GRU + viajes + estática ($\times 3$): $27 \cdot 42 \cdot 61$; survival stacking: $14 \cdot 24 \cdot 42$	Los secuenciales superan a survival stacking con evidencia al 10–20 %
Búsqueda bayesiana de la GRU (130 ensayos, Optuna [16])	La mejor configuración empata con la base al re-medirla con semillas nuevas (0,469 contra 0,471)	La semilla mueve más que los hiperparámetros: se usa un ensamble de 3
10 semillas, ensambles heterogéneos, MiniRocket	Ninguno mejora al 5–10 %; MiniRocket pierde -16 al 10 %, IC $[-26; -8]$	Límite de información, no de capacidad
GRU con etiqueta suave lejos del evento	$+9,6$, IC $[3,0; 14,4]$ en desarrollo; $-13,3$, IC $[-25,0; +3,9]$ en prueba	No generaliza (§5.1.5)

red es unidireccional porque el eje es kilómetros recorridos: un estado en el km 200 de la ventana no debe depender del km 900.

Los estados se resumen con una atención aditiva de una cabeza [13],

$$e_t = \mathbf{v}^\top \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a), \quad \alpha_t = \frac{\exp e_t}{\sum_{t'} \exp e_{t'}}, \quad \mathbf{h}^* = \sum_{t=1}^T \alpha_t \mathbf{h}_t, \quad (18)$$

con $\mathbf{W}_a \in \mathbb{R}^{16 \times d}$, que puede tomar directamente un tramo intermedio de la ventana sin arrastrarlo por todos los siguientes. Las variables estáticas $\mathbf{s}$ (país, motor y serie en codificación *one-hot*) pasan por una capa $\mathbf{u} = \text{ReLU}(\mathbf{W}_s \mathbf{s} + \mathbf{b}_s) \in \mathbb{R}^4$, y la cabeza produce el puntaje

$$\hat{p}_{i,c} = \sigma(\mathbf{w}_2^\top \text{ReLU}(\mathbf{W}_1 [\mathbf{h}^*; \mathbf{u}] + \mathbf{b}_1) + b_2), \quad \mathbf{W}_1 \in \mathbb{R}^{16 \times 28}. \quad (19)$$

El total es de 3.901 parámetros: 2.952 en la GRU, 416 en la atención, 52 en la rama estática y 481 en la cabeza.




Figura 5: Arquitectura del modelo finalista.

Entrenamiento. Se minimiza la entropía cruzada binaria ponderada sobre las ~ 11.700 filas de desarrollo,

$$\mathcal{L} = -\frac{1}{N} \sum_{(i,c)} \left[w_+ y_{i,c} \log \hat{p}_{i,c} + (1 - y_{i,c}) \log(1 - \hat{p}_{i,c}) \right], \quad w_+ = \frac{N_-}{N_+}, \quad (20)$$

donde N_+ y N_- son las filas positivas y negativas del entrenamiento de cada pliegue (no se remuestrea). Se usa Adam [17] con tasa de aprendizaje 10^{-3} , decaimiento de pesos 10^{-4} , lotes de 64, recorte de gradiente en norma 1, *dropout* de 0,3 y 40 épocas fijas. No hay detención temprana porque una validación interna por filas mezclaría cortes del mismo vehículo. La red es pequeña a propósito: con 135 vehículos con evento, una red grande memoriza vehículos en lugar de hábitos.

Ensamble. Como la variación entre semillas supera a la de los hiperparámetros (Tabla 2), el puntaje final promedia los rangos percentiles de tres redes entrenadas con las semillas 42, 1 y 2 (fijadas de antemano, no elegidas por resultado):

$$s_{i,c} = \frac{1}{3} \sum_{k=1}^3 \text{rk}(\hat{p}_{i,c}^{(k)}), \quad \text{rk}(p) = \frac{\#\{(i',c') : \hat{p}_{i',c'}^{(k)} \leq p\}}{N}. \quad (21)$$

El rango hace comparables escalas distintas y no modifica la métrica (7), que solo depende del orden.

5.1.3. Resultados en el conjunto de prueba

El conjunto de prueba son los 111 vehículos separados en la §4.3, de los cuales 103 tienen cortes válidos (32 con evento y 71 sanos). Cada modelo se entrenó con todo el conjunto de desarrollo y se evaluó una vez con la misma métrica. La Figura 6 muestra $D(\alpha)$ para todo el rango de presupuestos y la Tabla 3 resume los valores principales.




Figura 6: Detección $D(\alpha)$ según el presupuesto de falsas alarmas α en el conjunto de prueba $[test]$. La banda gris es la distribución nula, ec. (7) con puntajes permutados, hasta su percentil 95.

- Al 5 % de falsas alarmas se detectan 10 de 32 eventos: 4,5 veces la media del nulo y por encima de su percentil 95. Al 20 %, seis de cada diez.
- $\bar{D}$ duplica al de los modelos tabulares y de supervivencia (50,8 contra 21–27; frente a survival stacking, +24,2 puntos, IC [0,8; 43,0]).
- **Umbral fijado fuera de muestra.** Con τ_α calculado con los sanos de desarrollo, la detección en prueba es de 20, 34 y 57 % al 5, 10 y 20 %, con tasas de falsas alarmas realizadas de 5,8, 8,9 y 18,2 %: el umbral respeta su presupuesto en vehículos nuevos.

Tabla 3: Detección $D(\alpha)$ (%) del modelo finalista en el conjunto de prueba $[test]$. $\bar{D}$ según la ec. (8).

	$\alpha = 5 \%$	10 %	15 %	20 %	$\bar{D}$
GRU, ensamble de 3 semillas	31,2	46,9	62,5	62,5	50,8
Survival stacking	18,8	21,9	21,9	43,8	26,6
Nulo: media / percentil 95	7,0 / 15,6	13,7 / 25,0	18,6 / 31,2	24,4 / 40,6	–

- El resultado es consistente con el de desarrollo (27,4 · 42,5 · 53,3 · 60,7 %, $\bar{D} = 46,0$), y el AUC por vehículo en prueba es 0,794.

Incertidumbre. La misma configuración se evaluó tres veces en prueba y dio 34, 28 y 31 % al 5 %: el entrenamiento de la GRU no es determinista entre ejecuciones, y con 32 eventos cada vehículo representa 3 puntos. Por eso el resultado se reporta como rango: $\sim 30 \%$ al 5 %, $\sim 40\text{--}50 \%$ al 10 % y $\sim 50\text{--}60 \%$ al 20 %. Sin los 36 vehículos de prueba que habían estado en el desarrollo de la primera entrega, la detección es de 36,4, 50,0 y 59,1 % al 5, 10 y 20 %: el contacto previo con esos vehículos no infla el resultado.

5.1.4. Anticipación

Para cada vehículo detectado se mide la distancia entre la primera alerta sostenida (6) y la referencia del evento, $\ell_i = E_i - c_i^*$, donde c_i^* es el primero de los dos cortes consecutivos sobre τ_α . Por la ecuación (2), $\ell_i \geq G$.




Figura 7: Rango percentil medio del puntaje en los cortes sanos y en los cortes de vehículos con evento, según la distancia al evento $[test]$.

Al 10 % de falsas alarmas, la mediana de ℓ_i en prueba es de **4.646 km** (rango intercuartil 2.403–9.263 km), unos 99 días; al 5 %, 3.987 km (~ 72 días), y al 20 %, 5.969 km (~ 109 días). En desarrollo la mediana es de ~ 7.600 km (~ 86 días): los vehículos detectados en prueba recorren menos km por día, y en días el margen es similar. La Figura 7 muestra que el puntaje crece hacia el evento (rango medio 0,58 a más de 10.000 km, 0,61 entre 3.500 y 10.000 km y 0,72 a menos de 3.500 km, contra 0,44 en los sanos), pero con una dispersión grande. La salida del modelo es, por lo tanto, un *margen* de anticipación y no un pronóstico del instante de falla.

5.1.5. Una variante que no generalizó

Con la etiqueta (3), un corte lejano de un vehículo que va a fallar se entrena como negativo. Se evaluó una variante que le asigna una etiqueta suave $y_{i,c} = 0,15$ a los cortes con $E_i - c > G + H$. En una confirmación en desarrollo, con criterios fijados de antemano y semillas y pliegues nuevos, mejoraba $\bar{D}$ en +9,6 puntos (IC [3,0; 14,4]). En la única evaluación en prueba, también fijada de

antemano, dio 31,2 contra 44,5 ($-13,3$, IC $[-25,0; +3,9]$): perdió la capacidad de ordenar entre sí vehículos de características similares, que era justamente lo que la hacía ganar en desarrollo. La confirmación había usado pliegues y semillas nuevos, pero sobre los mismos 446 vehículos en los que se habían explorado unas 20 variantes. El finalista es la GRU con la etiqueta dura porque era la referencia establecida antes de abrir el conjunto de prueba, no porque se la haya elegido mirándolo.

5.2. Criterios de evaluación

5.2.1. Viabilidad técnica

El sistema no requiere sensores nuevos: usa los resúmenes de viaje y los mensajes del filtro que el vehículo ya transmite. La red tiene ~ 3.900 parámetros y corre en CPU (las 56 corridas de la evaluación completa en desarrollo tardaron ~ 25 minutos en 24 núcleos), y el mismo código de variables se usa en entrenamiento y en producción. Para un millón de vehículos se estima un proceso diario de 1 a 2 horas en 8 a 16 vCPU, a validar con Ford. La Tabla 4 resume el camino a producción.

Tabla 4: Etapas de implementación.

Etapas	Alcance	Duración	Criterio para avanzar
0. Congelamiento	Reentrenar con los 557 vehículos y empaquetar pesos, umbrales y referencia del ensamble	1–2 semanas	Reproduce el puntaje de 20 vehículos de control
1. Sombra	Puntuar la flota real de un mercado sin emitir avisos	3–6 meses	Tasa de alertas $\approx \alpha$; detección realizada medida
2. Piloto activo	Avisos en una región, con grupo de control	6 meses	Fallas evitadas, costo por alerta, cambio de hábitos
3. Escala	Mercados validados, umbral por mercado	continuo	Monitoreo dentro de tolerancia

La etapa en sombra es la central: es la primera medición de la prevalencia real y de las falsas alarmas sobre la flota completa, y no sobre las listas extraídas para el desafío. El monitoreo sigue la tasa de alertas por mercado, la deriva de las variables de entrada, la detección realizada y la interrupción de fuentes de datos (como ocurrió con el contador de regeneraciones). El reentrenamiento es trimestral, con las mismas auditorías.

Prototipo. Se construyó una aplicación que reproduce semana a semana los 426 vehículos de desarrollo con el modelo finalista (sin vehículos de prueba), con tres vistas: la bandeja del responsable de posventa, la ficha del vehículo para el concesionario y el seguimiento posterior, más un control del presupuesto α . Al 5 % [*dev*] genera 53 alertas y 7 escalamientos; 39 de los 135 vehículos con evento reciben aviso, con una mediana de 15 semanas (~ 7.000 km) de margen, y 14 de 291 sanos reciben uno innecesario; 48 de las 53 alertas incluyen un hábito modificable. Al 20 %, 82 de 135 vehículos con evento reciben aviso y 58 sanos uno innecesario. Dos agentes de lenguaje redactan los textos (el redactor y el de clasificación, que no puede elegir una acción distinta de la que fija la política) y un verificador programado rechaza números que no estén en los datos del caso, lenguaje causal, certezas, promesas y síntomas del filtro en un texto al conductor. En la simulación completa se generaron 465 textos y 196 resúmenes, todos aprobados, con 40 intentos rechazados.

5.2.2. Costo

El 80 % del costo es la persona que opera el sistema, de modo que el costo marginal por vehículo es muy bajo. La implementación se estima en USD 70.000–110.000 por única vez. No se reporta un ahorro porque se desconoce el costo de una falla para Ford: con escenarios de

Tabla 5: Costo anual de operación estimado para un millón de vehículos (a validar con Ford).

Componente	USD por año	Supuesto
Variables y puntaje diario	2.500–6.000	proceso de 1–2 h en 8–16 vCPU
Agentes de lenguaje	1.000–3.000	~ 65.000 alertas por año, modelo pequeño
Reentrenamiento y monitoreo	5.000–10.000	trimestral, en CPU
Equipo de operación	60.000–80.000	1 persona de ML/MLOps
Total	~70.000–100.000	USD 0,07–0,10 por vehículo y año

precios públicos, el sistema es rentable cuando anticipar una falla vale entre ~ 5 y ~ 15 veces una inspección y la prevalencia real es del 2 al 5 %. El diseño reduce el costo de un error porque el primer contacto es un consejo y no un turno. Esto es necesario: en una flota real la mayoría de los avisos irán a vehículos que no iban a fallar. Con una prevalencia π , el valor predictivo positivo es

$$\text{VPP} = \frac{\pi D(\alpha)}{\pi D(\alpha) + (1 - \pi) \alpha}, \quad (22)$$

que con $\pi = 5\%$, $\alpha = 5\%$ y $D = 30\%$ da $\sim 0,24$: unos 2 de cada 10 avisos corresponden a un vehículo que iba a fallar. La pérdida de consumo asociada a la saturación no se pudo medir con estos datos y es una métrica del piloto.

5.2.3. Carácter innovador

1. **Una métrica que no se satisface con atajos:** detección por vehículo a presupuesto de falsas alarmas, contrastada con un nulo que conserva el historial (7), en lugar de un PR-AUC que se alcanza sin anticipar.
2. **Un modelo que lee la ventana en orden** (14)–(18) y duplica la detección de los modelos tabulares en prueba.
3. **IA generativa con restricciones:** el modelo decide, el agente redacta y el código verifica; el modelo de lenguaje nunca produce un número ni un diagnóstico.
4. **La explicación como comparación y no como causa**, y el presupuesto α como un parámetro operativo en manos de Ford.
5. **Rigor metodológico como parte del producto:** criterios fijados antes de medir, auditorías obligatorias y un conjunto de prueba que se usó para medir y no para elegir.

5.2.4. Claridad en la presentación de los datos

Cada figura del informe responde a una pregunta y se genera desde un archivo de configuración. La figura central es la curva de detección contra falsas alarmas con el nulo dibujado (Figura 6). El prototipo muestra el calendario de la flota, la ficha del vehículo con su puntaje contra el umbral y sus hábitos contra la flota sana, y el control de α . La presentación oral recorre la misma historia con los mismos números y criterios: toda detección junto a su nulo, el resultado de prueba como rango y la anticipación como margen.

5.2.5. Explicabilidad del modelo

Importancia por permutación. Para medir en qué se apoya la GRU se permuta cada canal k entre los cortes de validación, moviendo sus T tramos juntos para conservar la forma de la serie, y se mide la caída del criterio primario [18]:

$$I_k = \bar{D} - \bar{D}(\mathbf{X}^{\pi_k}), \quad (23)$$

donde $\mathbf{X}^{\pi_k}$ es el tensor con el canal k permutado. Las variables estáticas se tratan igual. Las caídas no son aditivas, porque los canales están correlacionados.




Figura 8: Importancia por permutación I_k , ec. (23), en puntos de $\bar{D}$ [dev], sobre una base de 51,9 %.

El hábito de mayor peso es la duración de los viajes ($I = -24,1$ puntos), seguido de km por viaje, velocidad, motor bajo régimen y ralentí (Figura 8). Del estado del filtro, la variable principal es la subida de la acumulación ($-22,2$). El país pesa más que cualquier señal individual ($-28,1$): el riesgo de base no es el mismo en todos los mercados. El patrón coincide con la física de la ecuación (1) (viajes cortos que no completan la regeneración y hollín que se acumula), sin que se le haya provisto al modelo ninguna regla del filtro.

Explicación al conductor. La GRU no ofrece una atribución confiable por vehículo, y 7 de sus 15 canales describen el estado del propio filtro, que el conductor no controla. Por eso la explicación que se comunica es una comparación: los hábitos (hasta tres) en los que el vehículo supera al percentil 75 de los sanos de su mercado, restringidos a los modificables cuyo efecto coincide con la física del DPF. En un análisis de atribución sobre el modelo de supervivencia, 10 de 15 hábitos con hipótesis física coincidían con ella y cuatro tenían el signo contrario; esos últimos no se comunican. Los síntomas y el contexto se informan solo al taller, y el texto al conductor dice “comparado con vehículos sanos de su zona”, nunca “porque”.

6. Información complementaria

Documentación utilizada. El conjunto de datos y su diccionario se recibieron en dos entregas, y el diccionario se contrastó con los archivos columna por columna (§4). Cada hallazgo, decisión y experimento quedó documentado con su fecha, su motivo y el procedimiento que lo reproduce, y cada experimento está definido por un archivo de configuración versionado.

Información que solo Ford puede aportar. El límite actual no es el modelo sino la información disponible:

1. **La tasa real de eventos** en la flota, que permite separar la física del criterio con que se extrajeron las listas. Es la principal incertidumbre del trabajo.
2. **El origen de los 278 vehículos con evento y fecha por defecto** que salieron entre entregas, y el criterio de armado de la lista de vehículos con evento.
3. **Qué registra la fecha del evento:** hoy se corre 21 días porque cae unas dos semanas después del taller.
4. **Más eventos registrados** (hoy son 177), **la zona de uso** del vehículo (no la de venta) y **los costos reales** de una falla y de una inspección.
5. **Un piloto en sombra de tres meses en un país**, para medir prevalencia, falsas alarmas y detección reales.

Trabajo futuro. Reentrenar con los 557 vehículos y empaquetar el modelo. Validar toda mejora con datos nuevos (una extracción posterior al 14-09-2026) y no con este conjunto de prueba, que ya fue utilizado. Medir en el piloto lo que estos datos no permiten: si los avisos cambian hábitos, cuántas fallas se evitan y cuánto combustible se ahorra. Extender el circuito a otras fallas del sistema de postratamiento.

7. Conclusión

Se mostró que la telemetría que Ford ya recibe contiene información que anticipa la saturación del filtro de partículas, y que esa información es consistente con la física de la regeneración: los vehículos que fallan pasan más tiempo detenidos con el motor en marcha y con el motor por debajo de su temperatura de régimen, y la diferencia crece hacia el evento. Se mostró también que los datos contenían sesgos de muestreo y de formato capaces de producir métricas favorables sin ninguna capacidad predictiva, y que el PR-AUC por fila tiene un piso de 0,177 alcanzable sin información temporal. Por eso el modelo se seleccionó con la detección por vehículo a presupuesto de falsas alarmas, comparada con un nulo que conserva el historial.

Con ese criterio, el modelo finalista, una GRU con atención de ~ 3.900 parámetros en un ensamble de tres semillas, detecta en vehículos no vistos $\sim 30\%$ de los eventos con 5% de falsas alarmas y $\sim 50\text{--}60\%$ con 20% , con una mediana de ~ 4.600 km (unos tres meses) de anticipación y un umbral que respeta su presupuesto fuera de muestra. Duplica la detección de los modelos tabulares y de supervivencia en el mismo conjunto. El circuito propuesto convierte cada alerta en un aviso verificable, con el punto de operación como decisión de Ford, a un costo estimado de USD 0,07–0,10 por vehículo y por año. La validación de su impacto sobre fallas evitadas requiere el piloto en sombra propuesto.

Referencias

- [1] Ford Motor Company (2026). *Ford Innovation Challenge III – AI Edition. Desafío: Data-Driven Powertrain Intelligence*. Documento del desafío y anexo de datos.
- [2] Guan, B., Zhan, R., Lin, H. y Huang, Z. (2015). Review of the state-of-the-art of exhaust particulate filter technology in internal combustion engines. *Journal of Environmental Management*, 154, 225–258.
- [3] van Noortwijk, J. M. (2009). A survey of the application of gamma processes in maintenance. *Reliability Engineering & System Safety*, 94(1), 2–21.
- [4] Roberts, D. R. et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929.
- [5] Saito, T. y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.
- [6] Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- [7] Nosek, B. A., Ebersole, C. R., DeHaven, A. C. y Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606.
- [8] Ke, G. et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems 30*.
- [9] Craig, E., Zhong, C. y Tibshirani, R. (2021). Survival stacking: casting survival analysis as a classification problem. *arXiv:2107.13480*.
- [10] Tutz, G. y Schmid, M. (2016). *Modeling Discrete Time-to-Event Data*. Springer.

- [11] Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [12] Cho, K. et al. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. En *Proceedings of EMNLP 2014*, 1724–1734.
- [13] Bahdanau, D., Cho, K. y Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. En *ICLR 2015*.
- [14] Dempster, A., Schmidt, D. F. y Webb, G. I. (2021). MiniRocket: A very fast (almost) deterministic transform for time series classification. En *Proceedings of KDD 2021*, 248–257.
- [15] Das, A., Kong, W., Sen, R. y Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. En *ICML 2024*.
- [16] Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of KDD 2019*, 2623–2631.
- [17] Kingma, D. P. y Ba, J. (2015). Adam: A method for stochastic optimization. En *ICLR 2015*.
- [18] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [19] Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15.

A. Auditorías de fuga de información y techo de cohorte

Además de las defensas de construcción (gap de 500 km sobre la referencia corrida, partición por vehículo con los duplicados unificados, variables solo hacia atrás y corte en el fin de extracción común), todo candidato se somete a tres auditorías [19]. Sea $s_{i,c}$ el puntaje fuera de pliegue y $AP(\cdot)$ el PR-AUC por fila.

- **(a0) Nulo global.** Se permutan las variables entre todas las filas, se reentrena y se exige $AP \approx \bar{y} = 0,058$. Si no cae a la tasa base, hay información que no proviene de las variables.
- **(a') Contribución del instante.** Sin reentrenar, se reemplaza cada puntaje por el promedio de su vehículo, $\bar{s}_i = \frac{1}{n_i} \sum_c s_{i,c}$, y se reporta $AP(s) - AP(\bar{s})$: lo que el modelo sabía sobre *cuándo*, más allá de *qué vehículo*.
- **(b) Atajo de calendario.** Se agregan como variables las columnas de calendario (fechas de producción y de venta, temperatura ambiente) y se marca un atajo si el ROC sube más de 0,02.

La permutación dentro de cada vehículo no es un nulo válido: conserva qué vehículos tienen evento y, en este panel, el PR-AUC sube en lugar de bajar.

Tabla 6: Auditorías en desarrollo [*dev*] (semilla 42 de cada modelo secuencial; tasa base 0,058).

Modelo	(a0) PR-AUC	(a')	(b) Δ ROC	Resultado
GRU + viajes + estática (finalista)	0,061	+0,001	+0,004	aprueba
GRU + viajes, sin estática	0,061	+0,003	+0,025	marca atajo
CNN-LSTM + viajes + estática	0,057	+0,009	+0,018	aprueba
Survival stacking + motor y serie	0,056	+0,025	+0,009	aprueba

Ningún modelo presenta fuga: con las variables permutadas, todos caen a la tasa base. Ninguno supera el techo de cohorte, y la contribución (a') es positiva pero pequeña en todos: lo

Tabla 7: PR-AUC por fila en desarrollo [*dev*], junto al techo de cohorte de la ec. (5).

	PR-AUC (lift)	(a')
Tasa base	0,057 (0,97)	−0,002
LightGBM	0,112 (1,92)	−0,019
Survival stacking	0,125 (2,14)	+0,016
GRU + viajes + estática, ensamble de 3	0,160 (2,74)	+0,006
Techo de cohorte (sin información del instante)	0,177 (3,03)	−

que separa es principalmente *qué vehículo*. El finalista no muestra el atajo de calendario, que sí aparecía en la misma GRU sin variables estáticas.

B. Resultados de todos los modelos

Cada modelo se entrenó con todo el conjunto de desarrollo (semilla 42, salvo los ensambles de 3) y se evaluó con la misma métrica en los 103 vehículos de prueba. Estas evaluaciones se hicieron después de la evaluación del finalista y son descriptivas: no se usaron para elegir.

Tabla 8: Detección $D(\alpha)$ (%) en el conjunto de prueba según el presupuesto de falsas alarmas [*test*]. “Prim.” es $\bar{D}$, ec. (8).

Modelo	2 %	5 %	10 %	15 %	20 %	25 %	30 %	Prim.	AUC auto	dev (5 · 10 · 20 %)
GRU ×3 (finalista)	15,6	31,2	46,9	62,5	62,5	65,6	68,8	50,8	0,794	27 · 42 · 61
CNN-LSTM ×3	3,1	15,6	56,2	56,2	68,8	68,8	68,8	49,2	0,790	22 · 41 · 62
Survival stacking	3,1	18,8	21,9	21,9	43,8	53,1	53,1	26,6	0,710	14 · 24 · 42
LightGBM (53 features)	0,0	15,6	25,0	28,1	34,4	53,1	56,2	25,8	0,725	18 · 28 · 42
Logística L2 (53 features)	0,0	6,2	12,5	31,2	34,4	46,9	53,1	21,1	0,679	15 · 23 · 37
SS + efecto aleatorio (GPBoost)	3,1	9,4	9,4	9,4	12,5	12,5	12,5	10,2	0,363	6 · 9 · 17
Azar, media / p95 (nulo de la GRU)	3,4 / 9,4	7,0 / 15,6	13,7 / 25,0	18,6 / 31,2	24,4 / 40,6	28,6 / 43,8	33,9 / 50,0	—	—	—

Tabla 9: Con el umbral fijado en desarrollo [*test*]: detección y tasa de falsas alarmas realizada en prueba.

Modelo	Detección (%) al 5 · 10 · 20 %	Falsas alarmas reales (%)
GRU ×3 (finalista)	20 · 34 · 57	5,8 · 8,9 · 18,2
CNN-LSTM ×3	16 · 34 · 55	5,6 · 8,4 · 14,8
Survival stacking	13 · 20 · 33	4,6 · 8,3 · 15,6
LightGBM (53 features)	16 · 25 · 36	7,5 · 10,7 · 16,9
Logística L2 (53 features)	12 · 16 · 33	8,8 · 11,8 · 18,3
SS + efecto aleatorio (GPBoost)	8 · 11 · 14	6,5 · 11,3 · 21,5

Comparaciones pareadas en prueba (bootstrap por vehículo, diferencia de $\bar{D}$ en puntos, IC 95 %): survival stacking − GRU, −24,2 [−43,0; −0,8]; GRU con semillas 42, 1, 2 − GRU con semillas 101–103, +6,2 [−7,8; +18,0]; GRU con etiqueta suave − GRU con etiqueta dura, −13,3 [−25,0; +3,9].

Tabla 10: Modelos principales en desarrollo [*dev*]: $D(\alpha)$ (%), promedio de 3 repeticiones de la validación cruzada.

Modelo	AUC por vehículo	$\alpha = 5\%$	10%	20%
GRU + viajes + estática, ensamble de 3 (finalista)	0,82	27	42	61
CNN-LSTM + viajes + estática, ensamble de 3	0,81	22	41	62
Survival stacking	0,72	14	24	42
LightGBM (53 variables)	0,72	18	28	42
Logística L2	0,71	15	23	37
Nulo (historial conservado)	–	5	11	21

C. Diccionario de variables

Las 53 variables agregadas se calculan sobre la ventana $(c - W, c]$ según la ec. (10), como agregador(variable derivada). Las variables con prefijo *aux_* se conservan para auditoría y no entran en ningún modelo. Agregadores: *per_1000km*, conteo por 1.000 km; *per_day*, por día; *half_**, segunda mitad de la ventana menos la primera; *gap_**, distancia entre eventos; *any*, ocurrencia.

A · Térmica y trayectos cortos

idle_frac: mean(*idle*)
idle_per_1000km: *per_1000km*(*idle*)
idle_frac_trend: half_mean_delta(*idle*)
short_trip_frac_5km: mean(*short_trip_moving*)
trips_below_regime_temp_frac: mean(*below_regime*)
below_regime_moving_frac: mean(*below_regime_moving*)
below_regime_frac_trend: half_mean_delta(*below_regime*)
engine_temp_avg_median: median(*EngineTemperatureAvg_moving*)
engine_temp_max_median: median(*EngineTemperatureMax_moving*)
engine_temp_amplitude_mean: mean(*engine_temp_amplitude_moving*)
coolant_temp_end_mean: mean(*CoolantTemperatureEnd_moving*)
coolant_temp_start_median: median(*CoolantTemperatureStart*)
cold_start_frac: mean(*cold_start*)
chained_trip_frac: mean(*chained*)
trip_distance_median_km: median(*trip_km_moving*)
trip_distance_p25_km: p25(*trip_km_moving*)
trip_duration_median_min: median(*trip_duration_min_moving*)

B · Regeneración (DPF)

regenerations_per_1000km: *per_1000km*(*regen_drop*)
regenerations_trend_per_1000km: half_count_delta_per_1000km(*regen_drop*)
distance_between_regen_mean_km: gap_mean_km(*regen_drop*)
distance_between_regen_trend: gap_trend_km(*regen_drop*)
km_since_last_regen: km_since_last(*regen_drop*)
regen_residual_mean: mean(*regen_residual*)
regen_start_level_mean: mean(*regen_start_level*)
dpf_end_mean: mean(*AirRegenerationEnd*)
dpf_end_max: max(*AirRegenerationEnd*)
dpf_end_slope_per_1000km: half_slope_per_1000km(*AirRegenerationEnd*)

dpf_positive_delta_frac: mean(*dpf_positive_delta_moving*)
dpf_saturated_frac: mean(*dpf_saturated_end*)
filter_abnormal_end_frac: mean(*filter_abnormal_end*)
filter_cleaning_auto_end_frac: mean(*filter_cleaning_auto_end*)
manual_regen_ever: any(*filter_manual*)

C · Uso

speed_kmh_mean: mean(*speed_kmh_moving*)
trips_below_30kmh_frac: mean(*urban_moving*)
moving_trips_per_1000km: *per_1000km*(*moving*)
km_per_day: *per_day*(*trip_km*)
trips_per_day: *per_day*(*moving*)
hours_between_trips_median: median(*soak_min*)
aux_air_temp_avg: mean(*AirTemperatureAvg*)
aux_air_temp_min: mean(*AirTemperatureMin*)

D · Severidad (mensajes, aceite, consumo)

msg_full_per_1000km: *per_1000km*(*msg_full*)
msg_overloaded_per_1000km: *per_1000km*(*msg_overloaded*)
msg_overloaded_ever: any(*msg_overloaded*)
msg_over_limit_per_1000km: *per_1000km*(*msg_over_limit*)
msg_over_limit_ever: any(*msg_over_limit*)
msg_at_limit_ever: any(*msg_at_limit*)
msg_cleaning_auto_per_1000km: *per_1000km*(*msg_cleaning_auto*)
msg_cleaning_auto_trend_per_1000km: half_count_delta_per_1000km(*msg_cleaning_auto*)
msg_abnormal_frac: mean(*msg_abnormal*)
msgs_per_1000km: *per_1000km*(*msg_any*)
oil_life_mean: mean(*oil_life*)
oil_life_slope_per_1000km: half_slope_per_1000km(*oil_life*)
fuel_pct_per_100km_median: median(*fuel_pct_per_100km*)
aux_regen_marker_per_1000km: *per_1000km*(*regen_marker*)
Control de ventana
n_trips_window: count(*)
window_km_covered: rango(*OdometerTripEnd*)

Canales de la representación secuencial (11). La ventana se divide en 20 tramos de 50 km; “zero” rellena con cero un tramo sin datos y “carry” arrastra el último valor dentro de

la ventana. Se agregan país, motor y serie en codificación *one-hot*.

Canal	Fuente	Columna	Por tramo	Relleno
n_records	signals	*	count	zero · loglp
observed	signals	*	any	zero
acum_mean	signals	Acumulation	mean	carry
acum_max	signals	Acumulation	max	carry
acum_rise	signals	acum_rise	sum	zero
regen_drops	signals	acum_regen_drop	sum	zero
msg_full_frac	signals	msg_full	mean	zero
msg_severe_frac	signals	msg_severe	mean	zero
msg_cleaning_auto_frac	signals	msg_cleaning_auto	mean	zero
n_trips	trips	*	count	zero · loglp
idle_frac	trips	idle	mean	carry
below_regime_frac	trips	below_regime_moving	mean	carry
speed_kmh	trips	speed_kmh_moving	mean	carry
trip_km	trips	trip_km_moving	mean	carry
trip_duration_min	trips	trip_duration_min_moving	mean	carry